Computer Networks

4. Network layer: Data Plane 2

Network Layer - Data Plane: Overview

- Network layer: overview
  - data plane
  - control plane
- What's inside a router
  - input ports, switching, output ports
  - buffer management, scheduling
- IP: the Internet Protocol
  - datagram format
  - addressing
  - network address translation
  - IPv6
- Generalized Forwarding, SDN
  - match and action
  - OpenFlow

라우터 구조 개요

일반 라우터 구조에 대한 개요도:

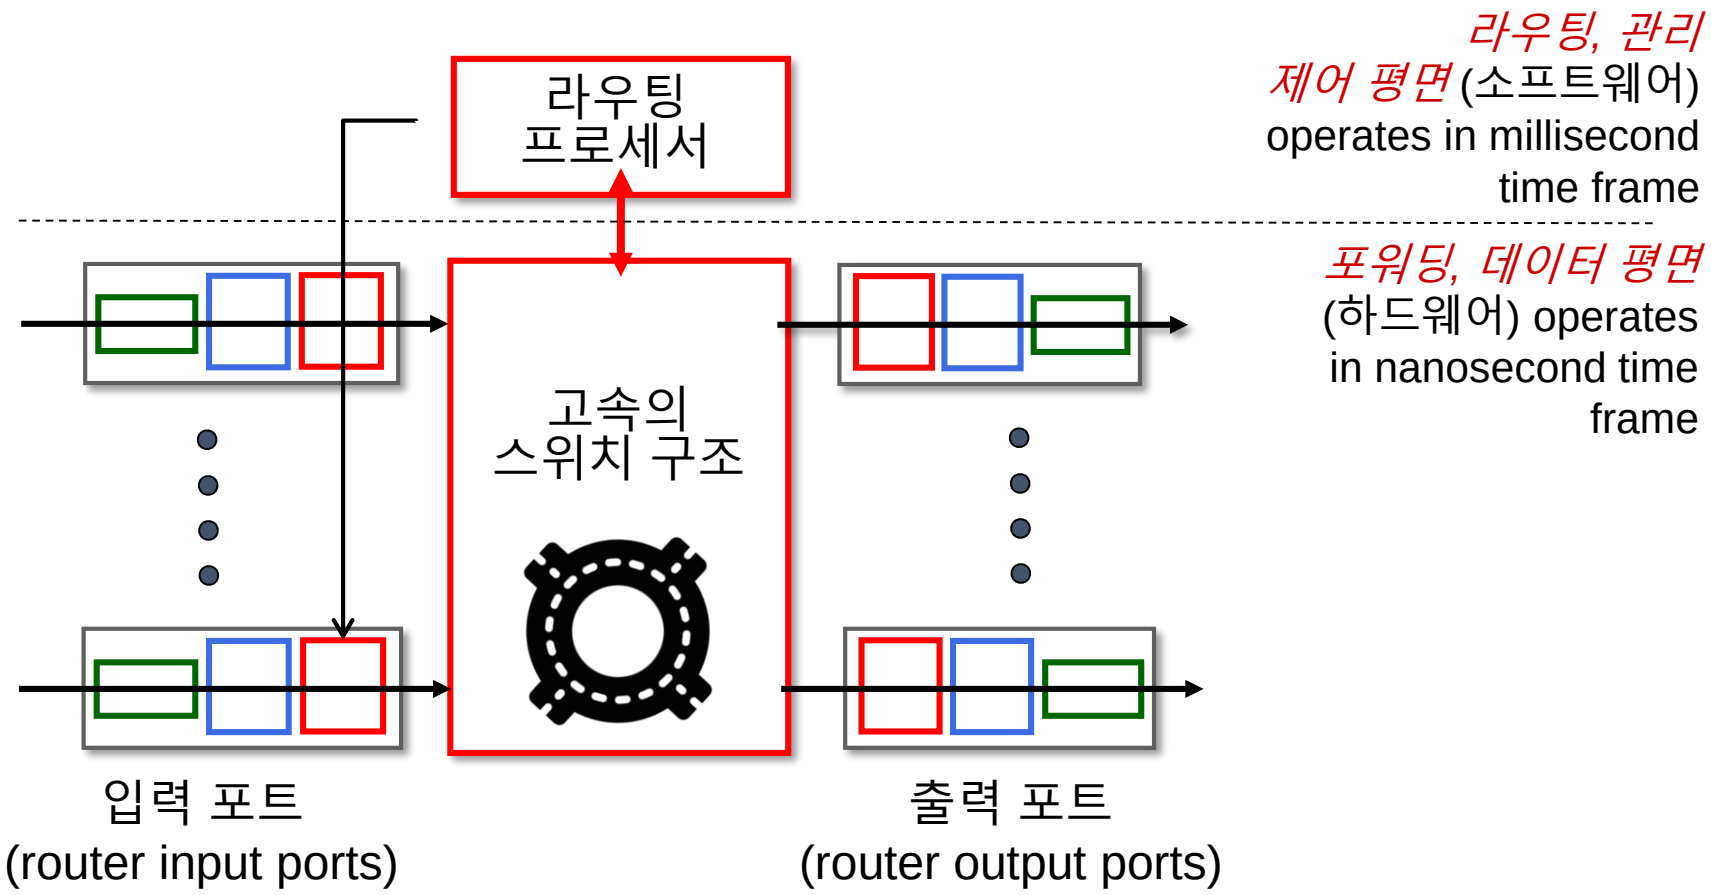

포트 (port): 물리적인 입출력 라우터 인터페이스

입력 포트 (Input port)의 역할

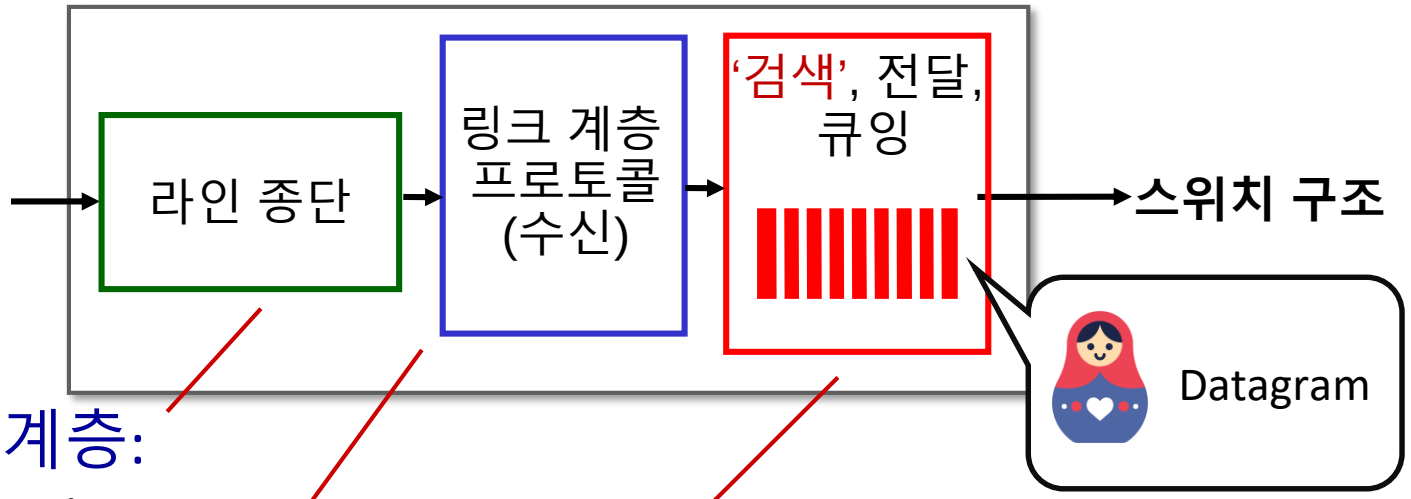

물리 계층:
bit-level reception

링크 계층:
데이터 링크 처리
(chapter 6)

Frame

분산된 스위칭: 포워딩 테이블은 각 입력 라인에 복사됨

- 헤더 필드의 값들을 사용하여 입력 포트 메모리의 포워딩 테이블에서 출력 포트를 조회 ('match plus action')
- Goal: '라인 속도'로 입력 포트 처리 완료
- 입력 포트 큐잉: 데이터그램이 스위치 구조로 전달되는 속도보다 빨리 도착하는 경우 발생

입력 포트 (Input port)의 역할

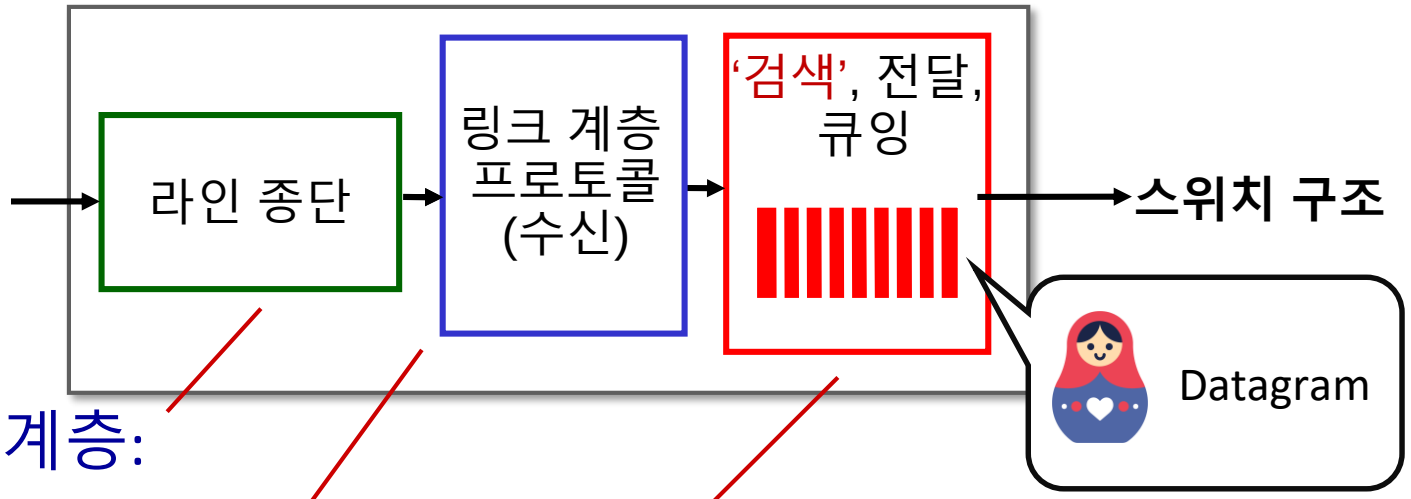

물리 계층:
bit-level reception

링크 계층:
데이터 링크 처리
(chapter 6)

Frame

분산된 스위칭: 포워딩 테이블은 각 입력 라인에 복사됨

- 헤더 필드의 값들을 사용하여 입력 포트 메모리의 포워딩 테이블에서 출력 포트를 조회 ('match plus action')
- 목적지 기반 전달 (destination-based forwarding): 목적지 IP 주소만을 기준으로 전달 (기존 방식)
- 일반화된 전달 (generalized forwarding): 어떤 헤더 필드 값들의 집합을 기준으로 전달 (SDN 방식)

목적지 기반 전달

forwarding table

Destination Address Range		Link Interface
11001000 00010111 00010000 00000000 through 11001000 00010111 00010111 11111111	200.23.16.0 ~ 200.23.23.255	0
11001000 00010111 00011000 00000000 through 11001000 00010111 00011000 11111111	200.23.24.0 ~ 200.23.24.255	1
11001000 00010111 00011001 00000000 through 11001000 00010111 00011111 11111111	200.23.25.0 ~ 200.23.31.255	2
otherwise		3

Q: 하지만 범위가 이렇게 잘 나누어지지 않으면 어떻게?

포워딩 테이블 출력 네트워크 명령어: netstat –rn

목적지 기반 전달

forwarding table

Destination Address Range		Link Interface
11001000 00010111 00010000 00000000 through 11001000 00010111 00010111 11111111	200.23.16.0 ~ 200.23.23.255	0
11001000 00010111 00010000 00000100 through 11001000 00010111 00010000 00000111	200.23.16.4 ~ 200.23.16.7	3
11001000 00010111 00011000 00000000 through 11001000 00010111 00011000 11111111	200.23.24.0 ~ 200.23.24.255	1
11001000 00010111 00011001 00000000 through 11001000 00010111 00011111 11111111	200.23.25.0 ~ 200.23.31.255	2
otherwise		3

최장 접두사 일치 (longest prefix matching)

Longest prefix match

지정된 대상 주소에 대한 포워딩 테이블의 항목 (entry)를 찾을 때, 대상 주소와 일치하는 가장 긴 주소 접두사를 가진 항목과 매칭

Destination Address Range	Link interface
11001000 00010111 00010*** ********	0
11001000 00010111 00011000 ********	1
11001000 00010111 00011*** ********	2
otherwise	3

examples:

11001000 00010111 00010110 10100001 which interface?

11001000 00010111 00011000 10101010 which interface?

최장 접두사 일치 (longest prefix matching)

Longest prefix match

지정된 대상 주소에 대한 포워딩 테이블의 항목 (entry)를 찾을 때, 대상 주소와 일치하는 가장 긴 주소 접두사를 가진 항목과 매칭

Destination Address Range	Link interface
11001000 00010111 00010*** ********	0
11001000 00010111 00011000 ********	1
11001000 00010111 00011*** ********	2
otherwise	3

match!

examples:

11001000	00010111	00010110	10100001	which interface?
11001000	00010111	00011000	10101010	which interface?

최장 접두사 일치 (longest prefix matching)

Longest prefix match

지정된 대상 주소에 대한 포워딩 테이블의 항목 (entry)를 찾을 때, 대상 주소와 일치하는 가장 긴 주소 접두사를 가진 항목과 매칭

Destination Address Range	Link interface
11001000 00010111 00010*** ********	0
11001000 00010111 00011000 ********	1
11001000 00010111 00011*** ********	2
otherwise	3

match!

examples:

11001000 00010111 00010110 10100001	which interface?
11001000 00010111 00011000 10101010	which interface?

최장 접두사 일치 (longest prefix matching)

Longest prefix match

지정된 대상 주소에 대한 포워딩 테이블의 항목 (entry)를 찾을 때, 대상 주소와 일치하는 가장 긴 주소 접두사를 가진 항목과 매칭

Destination Address Range	Link interface
11001000 00010111 00010*** ********	0
11001000 00010111 00011000 ********	1
11001000 00010111 00011*** ********	2
otherwise	3

match!

examples:

11001000 00010111 00010110 10100001	which interface?
11001000 00010111 00011000 10101010	which interface?

최장 접두사 일치 (longest prefix matching)

- 최장 접두사 매칭은 보통 TCAM(Ternary Content Addressable Memory)과 같은 전용 하드웨어를 이용해 매우 빠르게 수행됨
  - Ternary는 0, 1, don’t care(*)의 3가지 값을 의미
  - don’t care 값을 사용할 수 있어 prefix 기반 비교에 적합
  - TCAM은 목적지 주소를 입력하면 엔트리들을 병렬 비교하여, 테이블 크기에 크게 영향받지 않고 한 클록 사이클 내에 일치하는 엔트리를 찾을 수 있음
  - [예] Cisco Catalyst는 약 100만 개의 라우팅 엔트리를 TCAM에서 처리 가능

스위치 구조

- 입력 포트에서 적절한 출력 포트로 패킷 스위칭 (전달/전송)
- 스위칭 속도 (switching rate): 패킷을 입력 포트에서 출력 포트로 전달할 수 있는 속도
  - 입력/출력 라인 속도 (line rate, R)의 배수로 나타낼 수 있음
  - 입력 포트가 N개이면, 스위칭 속도는 라인 속도의 N배 이상이 되어야 함

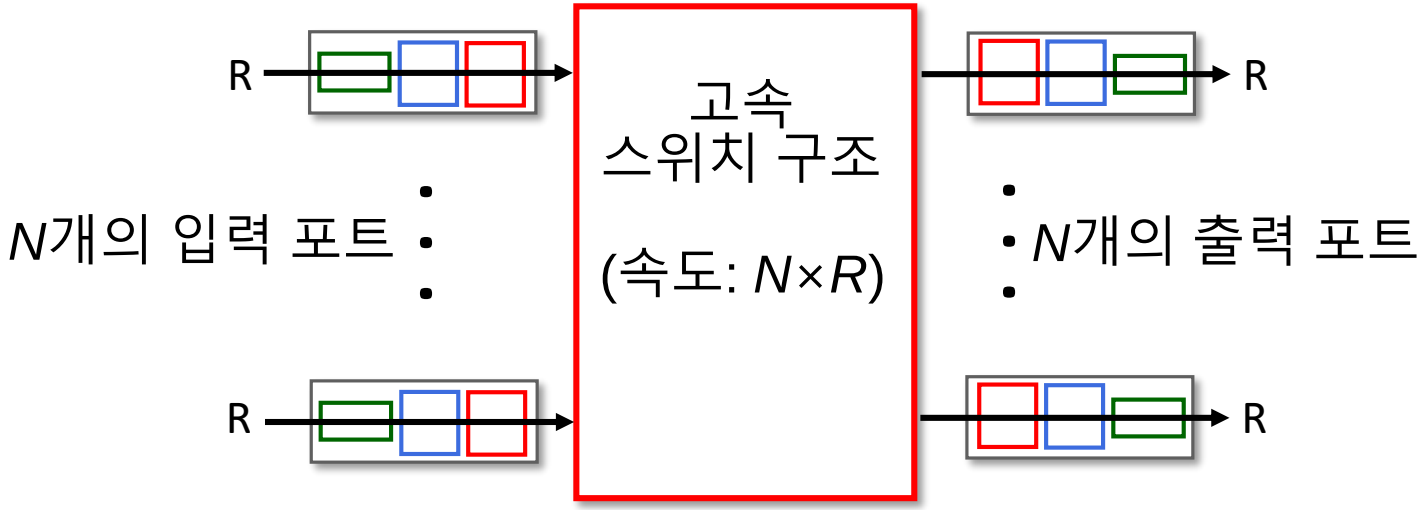

스위치 구조

- 입력 포트에서 적절한 출력 포트로 패킷 스위칭 (전달/전송)
- 스위칭 속도 (switching rate): 패킷을 입력 포트에서 출력 포트로 전달할 수 있는 속도
  - 입력/출력 라인 속도 (line rate, *R*)의 배수로 나타낼 수 있음
  - 입력 포트가 *N*개이면, 스위칭 속도는 라인 속도의 *N*배 이상이 되어야 함
- 세 가지 주요 스위칭 구조 타입:

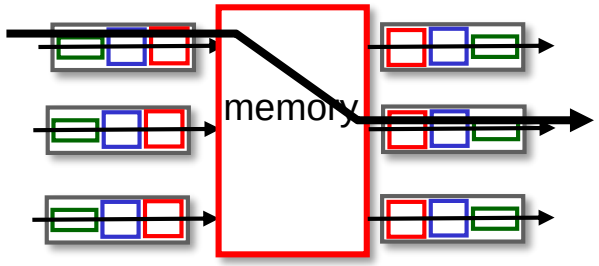

메모리

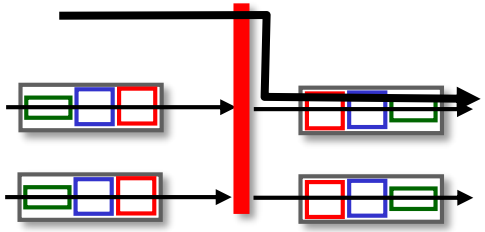

버스

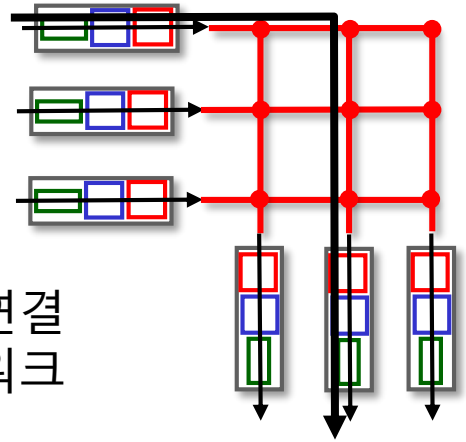

상호연결
네트워크

메모리를 통한 스위칭

- 초기 라우터의 동작 방식
  - CPU (라우팅 프로세서)를 직접 제어해서 입력 포트와 출력 포트 사이에서 패킷을 스위칭하는 전통적인 컴퓨터
- 입력 포트에 도착한 패킷을 시스템 메모리에 복사됨
- 메모리 대역폭 (*B*)에 의해 스위칭 속도가 제한됨: ≤ B/2
- 데이터그램이 시스템 버스를 2번씩 사용
  - 시스템 버스가 공유되므로 한번에 하나의 패킷만 전달 가능

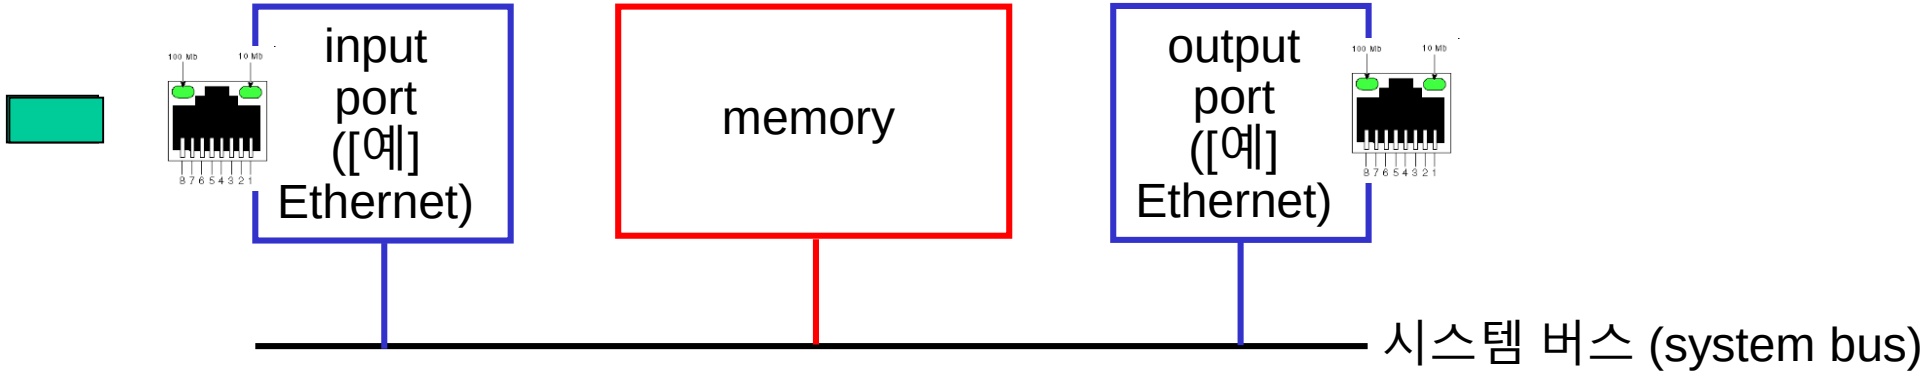

버스를 통한 스위칭

- 라우팅 프로세스의 개입 없이 공유 버스를 통해 입력 포트 메모리에서 출력 포트 메모리로 직접 데이터그램을 스위칭
- 버스 경쟁: 버스 대역폭에 의해 스위칭 속도가 제한됨
- 32 Gbps bus, Cisco 5600: 소규모 기관 네트워크, 접속 네트워크의 라우터에서 충분한 속도 제공

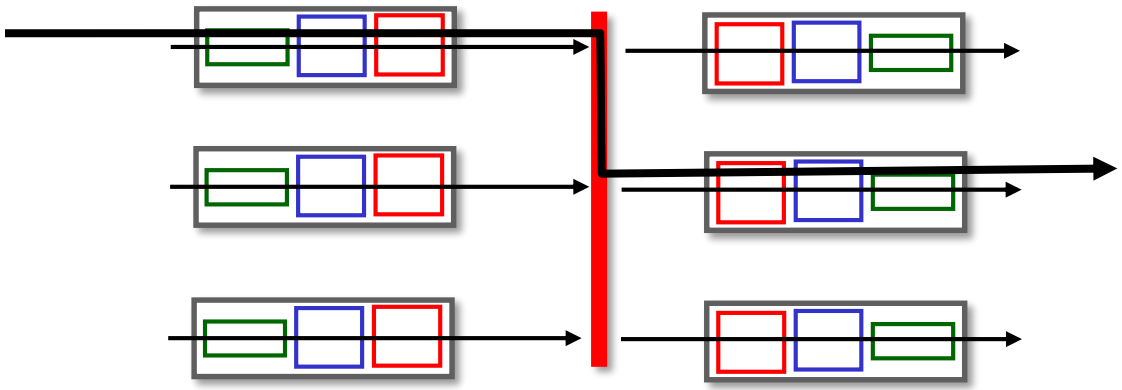

상호연결 네트워크를 통한 스위칭

- 크로스바 스위치 (crossbar switch), 다단계 상호연결망 등 멀티 프로세서 컴퓨터 구조에서 프로세서들을 연결하기 위해 개발된 상호연결망을 활용
- 다단계 스위치 (multistage switch): 여러 단계의 소형 스위칭 소자들로 구성
- 병렬 처리 활용:
  - 스위치 구조에 진입 시 데이터그램을 고정 길이의 청크들로 분해
  - 출력 포트는 청크들을 원래 데이터그램으로 재조립

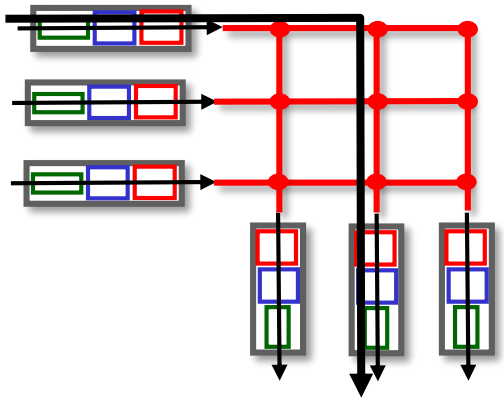

3x3 crossbar

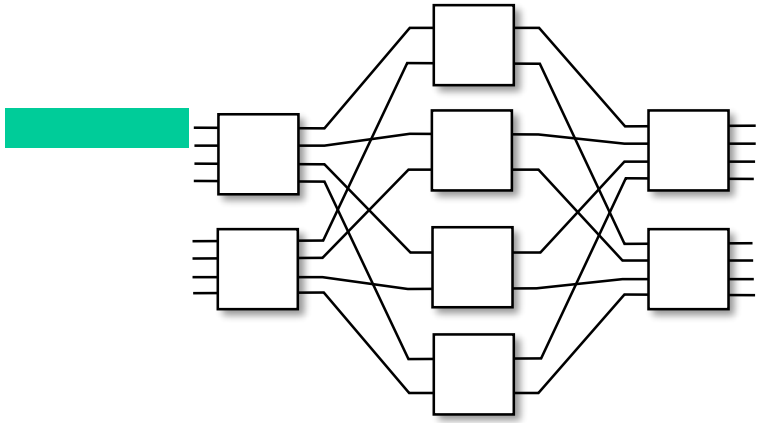

8x8 multistage switch
built from smaller-sized switches

상호연결 네트워크를 통한 스위칭

- 다중 스위치 구조를 병렬로 실행하여 라우터의 스위칭 용량을 확장
  - 속도 향상, 병렬 처리를 통한 확장
- Cisco CRS (Carrier Routing System) 라우터: 3단계 논블로킹 스위칭 구조
  - 8개의 스위칭 평면 (switching plane)으로 구성되며, 각 평면은 3단계 상호연결 네트워크 구조로 설계되어 포트 간 병목 없이 연결 가능
  - 총 스위칭 속도는 수백 Tbps에 달하며, 백본망 등 대규모 통신망에서 활용됨

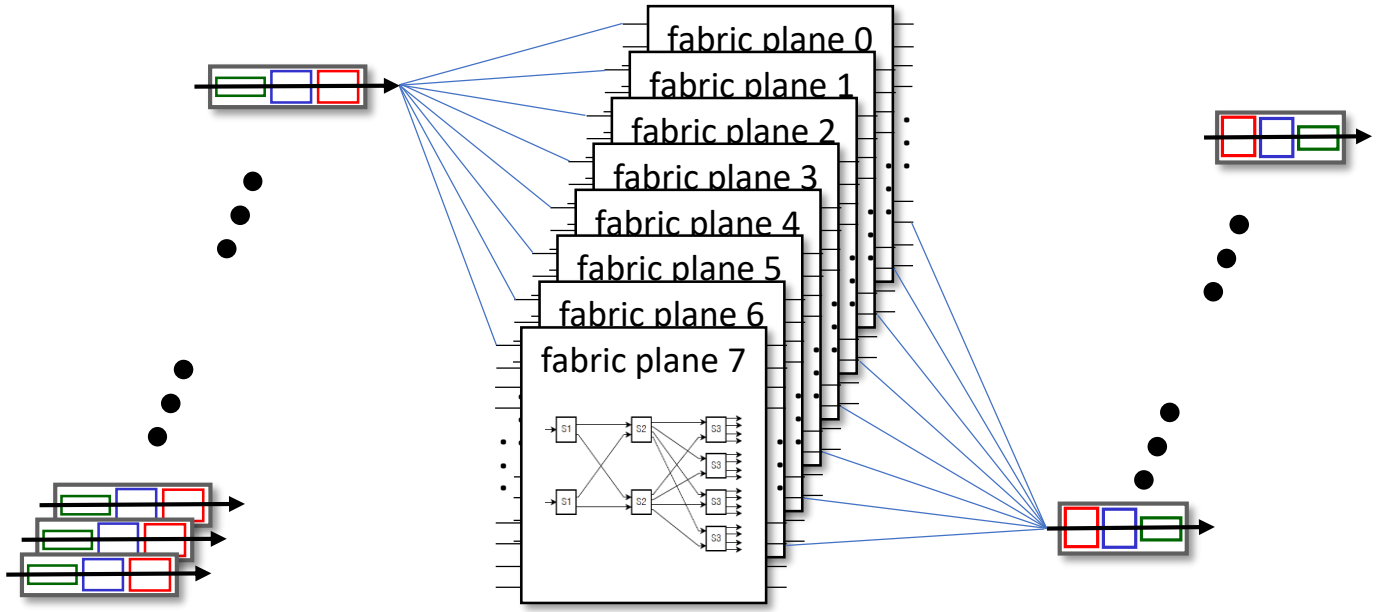

입력 포트 큐잉

- 스위칭 속도가 결합된 입력 포트들 보다 느리면, 입력 포트의 버퍼에서 큐잉이 발생
  - 입력 포트 버퍼의 오버플로 (overflow) 때문에 큐잉 지연과 패킷 손실이 발생할 수 있음
- Head-of-the-Line (HOL) 블로킹: 앞에 대기 중인 패킷 때문에 뒤에 있는 다른 패킷이 출력 포트로 스위칭 될 수 없음

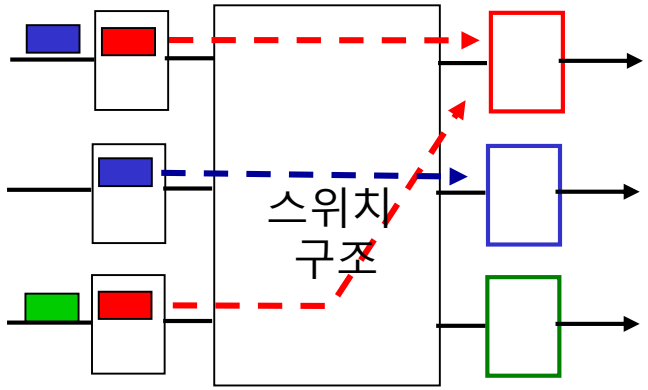

출력 포트 경쟁 발생: 하나의 빨간색 패킷만 전송될 수 있음. 밑에 있는 빨간색 패킷은 블로킹됨

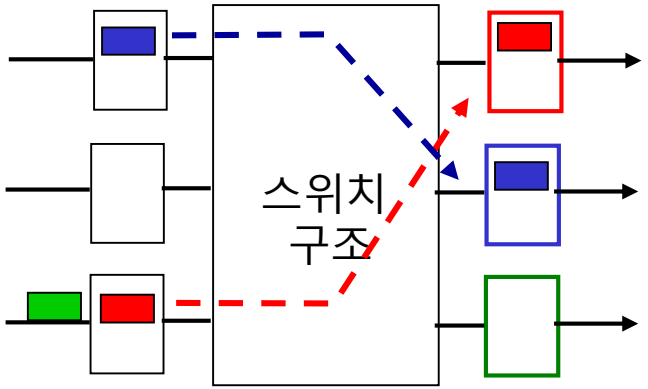

한 패킷 스위칭 시간 이후: 녹색 패킷은 HOL 블로킹을 경험

출력 포트 큐잉

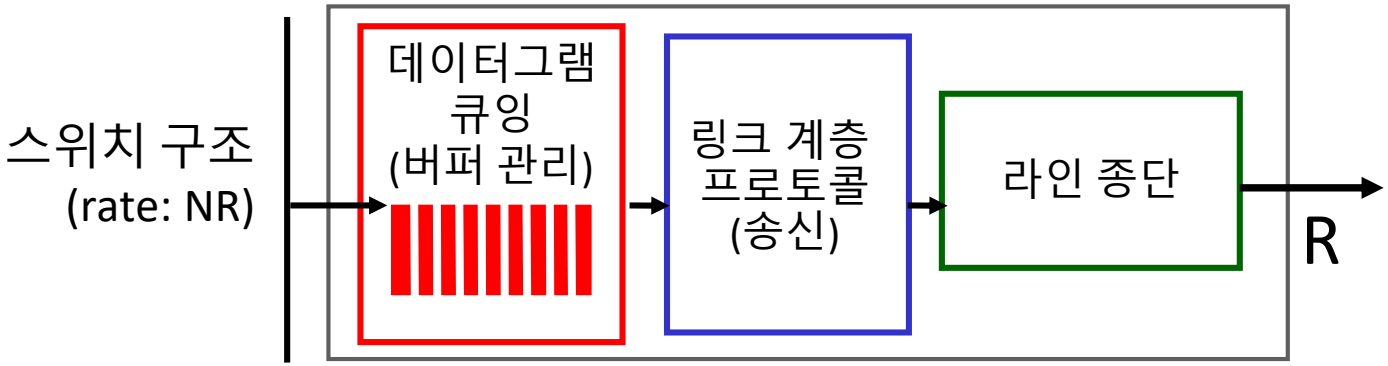

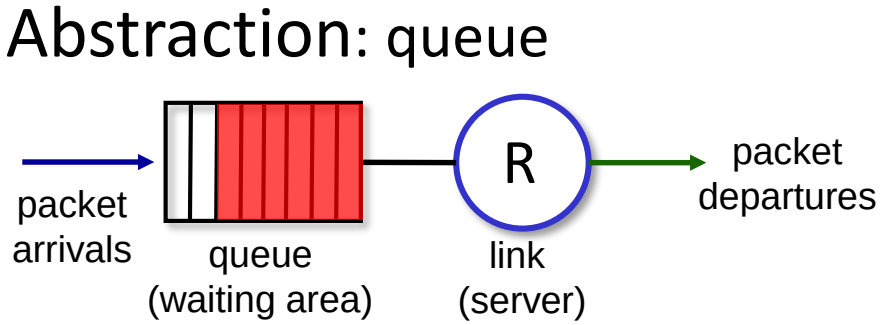

- 스위치 구조에서 패킷이 출력 포트의 링크 전송 속도보다 빠르게 전달되면, 버퍼링 (buffering)이 필요함
  - 출력 포트 버퍼의 오버플로 (overflow) 때문에 큐잉 지연과 패킷 손실이 발생 할 수 있음

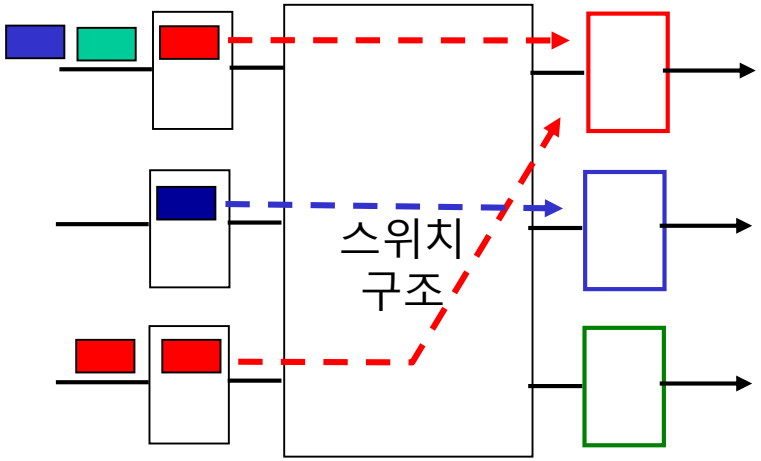

출력 포트 경쟁

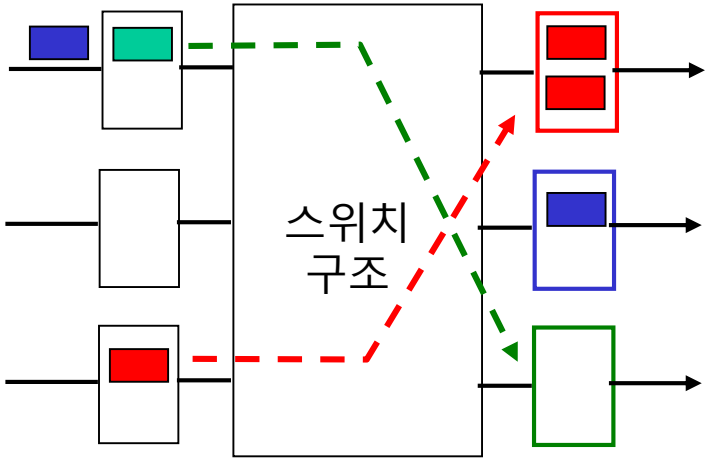

스위칭 속도가 출력 포트의 전송 속도보다 훨씬 빠르면 버퍼링 발생

얼마나 많은 버퍼가 요구되는가?

- RFC 3439 권장: 평균 버퍼링 크기가 C일 때, $C = RTT \times B$
  - 일반적인 RTT (즉, 250 ms), B는 링크 대역폭
  - [예] 링크 대역폭이 10 Gbps이면, 2.5 Gbits 버퍼링

- 최신 권장: 독립적인 *N*개의 TCP 흐름이 있으면, 버퍼링 크기는 $\frac{RTT \cdot B}{\sqrt{N}}$

- 버퍼링이 클수록 라우터의 패킷 손실률은 감소
- 하지만, 너무 많은 버퍼링은 오히려 지연을 증가시킴
  - 긴 RTT 시간: 실시간 애플리케이션의 성능을 저하하고, 패킷 손실/혼잡에 대한 TCP 응답이 느림
  - 지연 기반 혼잡 제어: '충분히 채우되 (처리율 최대화), 꽉 채우지 말자! (지연 시간은 낮게 유지)'

버퍼 관리

패킷 스케줄러 (packet scheduler)

- 링크에 우선 전송할 패킷 또는 삭제할 패킷을 선택 → 망 중립성 문제

드롭 정책 (drop policy)

- 사용 가능한 버퍼가 없다면, 어떤 패킷부터 드롭 (삭제)?

버퍼 관리 (buffer management):

- drop: 버퍼에 새로운 패킷이 도착했지만, 버퍼가 가득 차 있다면?
  - tail drop: 도착한 패킷을 드롭
  - priority: 우선순위 기반으로 패킷을 드롭
  - random: 임의의 패킷을 드롭
- marking: 패킷에 혼잡 발생을 표시 (ECN)

스케줄링 정책: FCFS

패킷 스케줄링: 링크에 보낼 다음 패킷을 선택

- FCFS (first come, first served)
- 우선순위 (priority)
- 라운드 로빈 (round robin)
- 가중 공정 큐잉 (weighted fair queueing)

FCFS: 출력 포트에 도착한 순서대로 패킷을 전송

- 즉, First-in-first-out (FIFO)

우선순위 (priority) 스케줄링

우선순위 스케줄링

- 도착한 패킷을 분류하여, 우선순위 별로 버퍼링
  - 모든 헤더 필드들이 분류에 사용될 수 있음
- 버퍼링된 패킷이 있는 우선 순위가 가장 높은 버퍼부터 패킷을 전송
  - 같은 우선순위 내에서는 FCFS로 동작

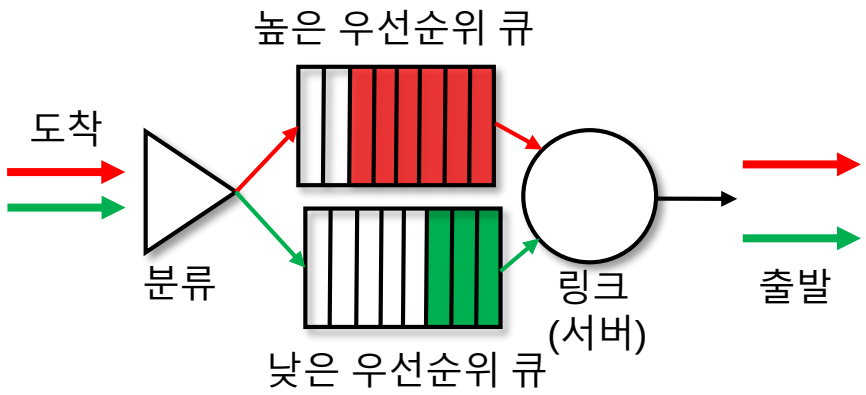

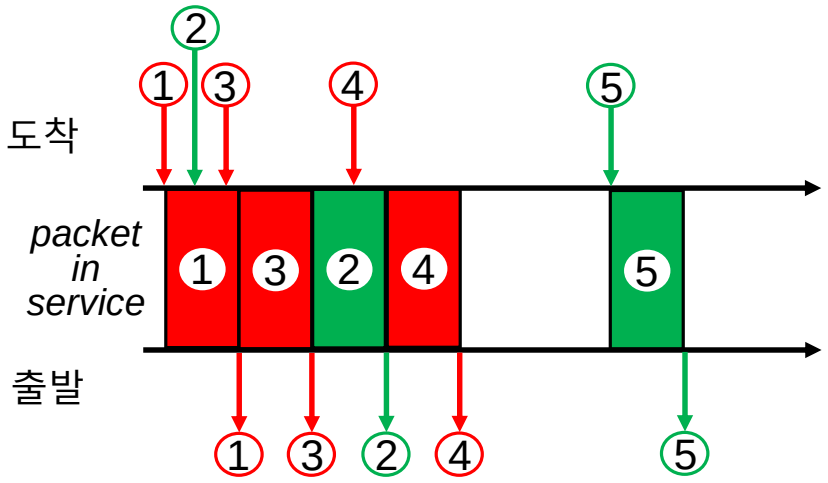

라운드 로빈 (round robin) 스케줄링

라운드로빈 스케줄링

- 도착한 패킷을 분류하여, 클래스 별로 버퍼링
  - 모든 헤더 필드들이 분류에 사용될 수 있음
- 주기적으로 클래스 버퍼들을 반복적으로 검사하면서, 버퍼링된 패킷이 있는 각 클래스에서 차례대로 하나의 패킷을 전송

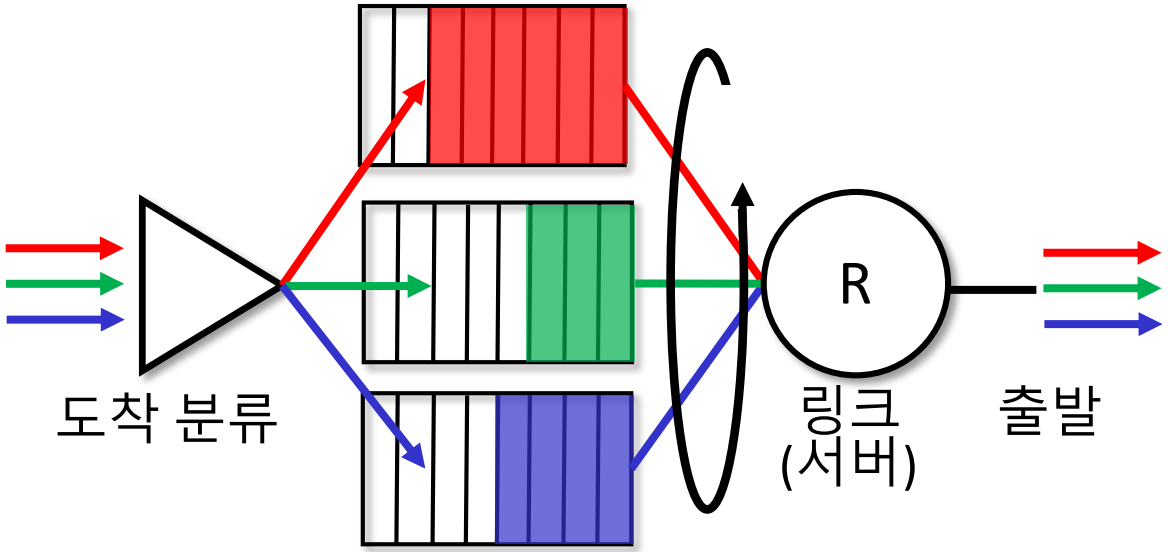

가중 공정 큐잉 (weighted fair queueing) 스케줄링

가중 공정 큐잉 (WFQ):

- 일반화된 라운드 로빈
- 각 클래스 i는 가중치 w_i를 할당 받으며, 각 주기에서 가중치 만큼 서비스 시간을 할당 받음

$$\frac{w_i}{\sum_j w_j}$$

- 트래픽 클래스 당 최소 대역폭을 보장

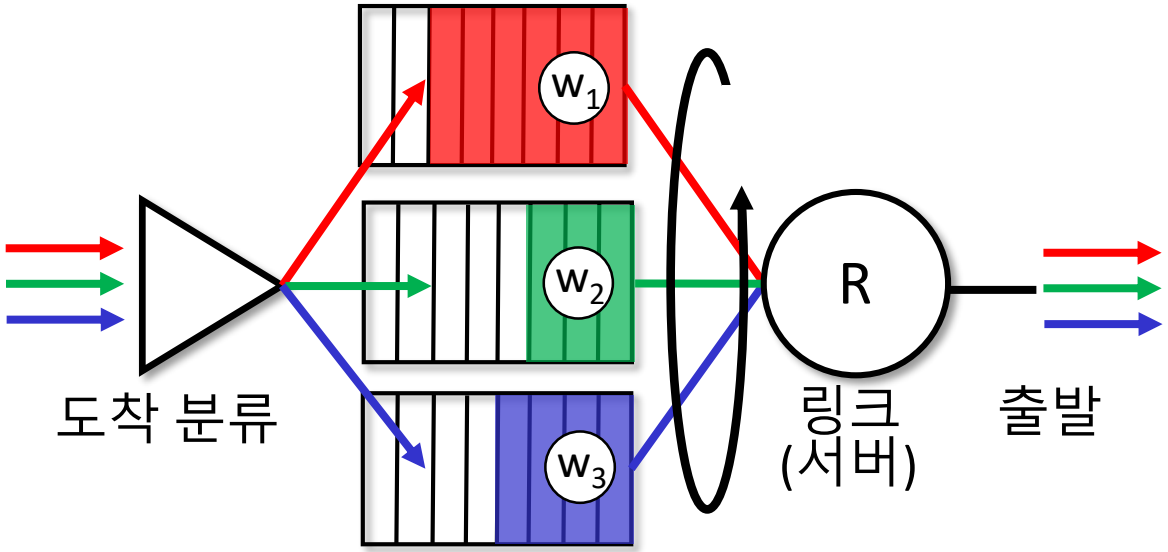

[TMI] 망 중립성?

망 중립성 (Network Neutrality):

- 모든 인터넷 트래픽을 동등하게 취급해야 한다는 원칙
  - ISP는 콘텐츠나 서비스 종류, 사용자, 목적지, 플랫폼 등에 따라 차별하거나 우선순위를 두면 안됨
- ISP는 네트워크 자원을 자체적으로 할당하거나 관리할 수 있음
  - [예] 패킷 스케줄링, 버퍼 관리 등
- 사회적, 경제적 원칙
  - 표현의 자유를 보장
  - 혁신과 시장 경쟁을 촉진

[TMI] 망 중립성 (Network Neutrality)

2015년 미국 연방통신위원회에서 개방형 인터넷 보호 및 촉진에 관한 명령에서 망 중립성에 대한 3가지 규칙을 제시

- 차단 금지 (no blocking): … “합당한 네트워크 관리에 따라 합법적인 콘텐츠, 애플리케이션, 서비스 또는 유해하지 않은 장치를 차단해서는 안된다.”
- 속도 저하 금지 (no throttling): … “합당한 네트워크 관리에 따라 인터넷 콘텐츠, 애플리케이션 또는 서비스 또는 유해하지 않는 장치의 사용을 기반으로 합법적인 인터넷 트래픽을 손상시키거나 저하시키서는 안된다.”
- 유료 우선순위 금지 (no paid prioritization): … “유료 우선순위에 관여해서는 안된다.”

Q & A