경사 하강법

국립금오공과대학교
시종욱

목차

- 경사 하강법
- 학습률

경사 하강법

- Cost Function의 고찰 (*b* 생략)

$$J(w,b) = \frac{1}{n}\sum_{k=1}^{n}\left(H(x^{(k)}) - y^{(k)}\right)^2$$

$$H(x) = \hat{y} = wx$$

$$J(w) = \frac{1}{n}\sum_{k=1}^{n}\left(wx^{(k)} - y^{(k)}\right)^2$$

경사 하강법

$$J(w) = \frac{1}{n}\sum_{k=1}^{n}\left(wx^{(k)} - y^{(k)}\right)^2$$

- w 선택

$x^{(k)}$	$y^{(k)}$
1	1
2	2
3	3
4	4
5	5

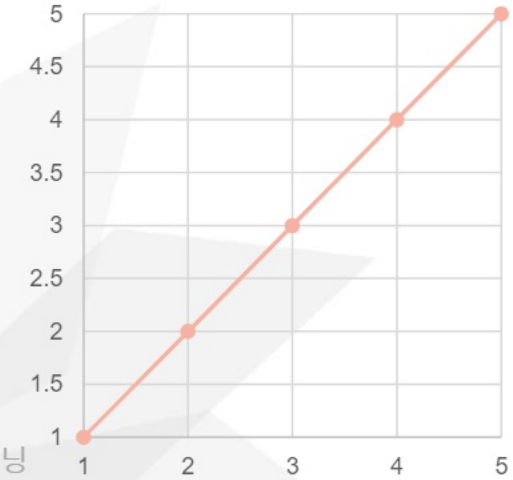

w 값

$J(0) = 11$

$J(1) = 0$

$J(2) = 11$

$J(3) = 44$

$J(4) = 99$

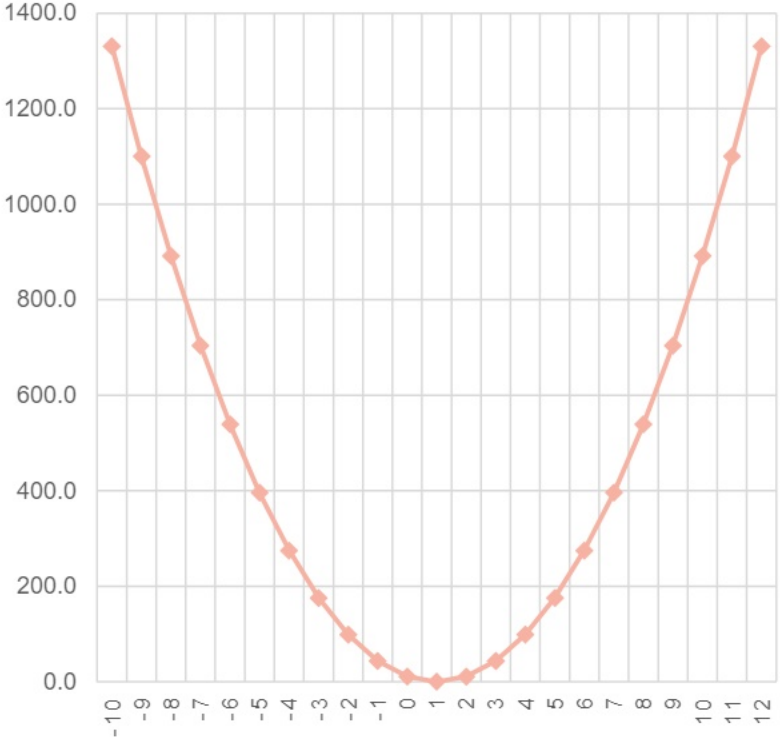

평균 제곱 오차에 대한 그래프

경사 하강법

- w 선택

$$J(w,b) = \frac{1}{n}\sum_{k=1}^{n}\left(H\left(x^{(k)}\right) - y^{(k)}\right)^2 \left(= \left(y^{(k)} - H\left(x^{(k)}\right)\right)^2\right)$$

잔차 벡터 (residual vector)

$$J(w,b) = \frac{1}{2n}\sum_{k=1}^{n}\left(H\left(x^{(k)}\right) - y^{(k)}\right)^2$$

$$\boxed{w^{(t+1)} := w^{(t)} - \alpha \frac{\partial}{\partial w} J(w,b)}$$

경사하강법

α: Learning rate

경사 하강법

- w 선택

$$w^{(t+1)} := w^{(t)} - \alpha \frac{\partial}{\partial w} \frac{1}{2n} \sum_{k=1}^{n} \left(H(x^{(k)}) - y^{(k)}\right)^2$$

$H(x) = wx$

$$w^{(t+1)} := w^{(t)} - \alpha \frac{\partial}{\partial w} \frac{1}{2n} \sum_{k=1}^{n} \left(wx^{(k)} - y^{(k)}\right)^2$$

학습률 크기 정하기

$$w^{(t+1)} := w^{(t)} - \alpha \frac{1}{n} \sum_{k=1}^{n} \left(wx^{(k)} - y^{(k)}\right) x^{(k)}$$

경사 하강법

- 경사 하강법(Gradient Descent)
  - 현재 지점의 오차를 확인하여 오차가 작은 지점으로 반복 이동하여 오차가 최소가 되는 지점을 찾는 방법
  - 오차가 작은 지점으로 이동하기 위해 미분 사용
  - 알고리즘
    - ✓ step 1: 현재 위치에서 미분을 사용하여 기울기 계산
    - ✓ step 2: 기울기의 반대 방향으로 일정 값 만큼 이동
      기울기 +: 음의 방향(그래프 왼쪽 방향)으로 이동
      기울기 -: 양의 방향(그래프 오른쪽 방향)으로 이동
    - ✓ step 3: 미분 값이 0 또는 최소값이 아니면 step 1로 돌아감

0.5

경사 하강법

- 경사 하강법(Gradient Descent)
  - 초기 값으로 시작 (w, b)
  - cost(w, b)가 감소하도록 w와 b를 조금씩 변경
  - minimum에 도달할 때까지 반복 수행
  - 시작하는 위치에 따라 도달하는 최저점이 결정됨

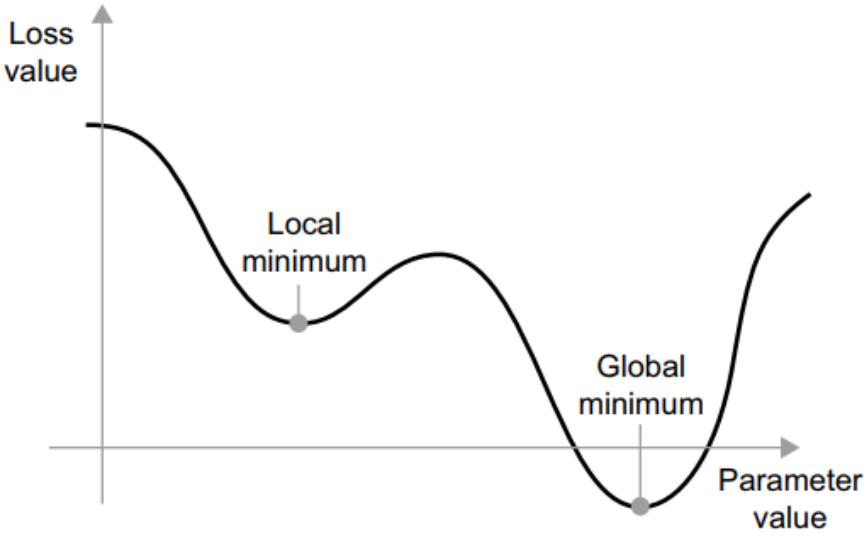

경사 하강법

- 경사 하강법(Gradient Descent)

$$w^{(t+1)} := w^{(t)} - \alpha \frac{\partial}{\partial w} \frac{1}{2n} \sum_{k=1}^{n} \left(H(x^{(k)}) - y^{(k)}\right)^2 \left(= \left(y^{(k)} - H\left(x^{(k)}\right)\right)^2\right)$$

잔차 벡터 (residual vector)

$H(x) = wx + b$

$$w^{(t+1)} := w^{(t)} - \alpha \frac{\partial}{\partial w} \frac{1}{2n} \sum_{k=1}^{n} \left(\left(wx^{(k)} + b\right) - y^{(k)}\right)^2$$

$$\begin{cases} w^{(t+1)} := w^{(t)} - \alpha \dfrac{1}{n} \displaystyle\sum_{k=1}^{n} \left(\left(wx^{(k)} + b\right) - y^{(k)}\right) \boxed{x^{(k)}} \\ b^{(t+1)} := b^{(t)} - \alpha \dfrac{1}{n} \displaystyle\sum_{k=1}^{n} \left(wx^{(k)} + b\right) - y^{(k)} \end{cases}$$

batch gradient descent

stochastic gradient descent

mini-batch gradient descent

경사 하강법

- 경사 하강법(Gradient Descent)
  - ➢ 방금까지 설명한 내용은 Batch Gradient Descent
  - ➢ 이 방법의 문제점
    - ✓ (1) 계산 비용이 큼: 전체 데이터셋을 사용해 기울기 계산,데이터가 클수록 한 번 업데이트가 매우 느림
    - ✓ (2) 학습 속도가 느림: 한 번 업데이트하려면 모든 샘플을 봐야 함, 대규모 데이터에 부적합
    - ✓ (3) 지역 최솟값 / 안장점 문제: local minimum, saddle point에 빠질 수 있음
    - ✓ (4) 메모리 부담: 전체 데이터가 메모리에 있어야 함

경사 하강법

- 확률적 경사 하강법(Stochastic Gradient Descent, SGD)
  - 샘플 1개로 기울기를 계산하여 즉시 업데이트
  - 장점: 빠름, 메모리 효율 높음
  - 단점: 수렴이 불안정

Batch: 한번에 고려하는 샘플의 개수.
Epoch: 전체 데이터 고려.
1Epoch → 샘플 데이터 개수, 갱신은 10000번
(10000개의 데이터가 있을 때)

- 미니 배치 경사 하강법(Mini-Batch Gradient Descent) ← 1 << _ << 전체
  - 일부 샘플 묶음(mini-batch)으로 기울기 계산, SGD와 Batch의 절충안
  - GPU 병렬 처리에 유리
  - 가장 실용적

GD	SGD	Mini-Batch GD
1	10000	100

(10000개 데이터, 1Epoch 비교)

학습률

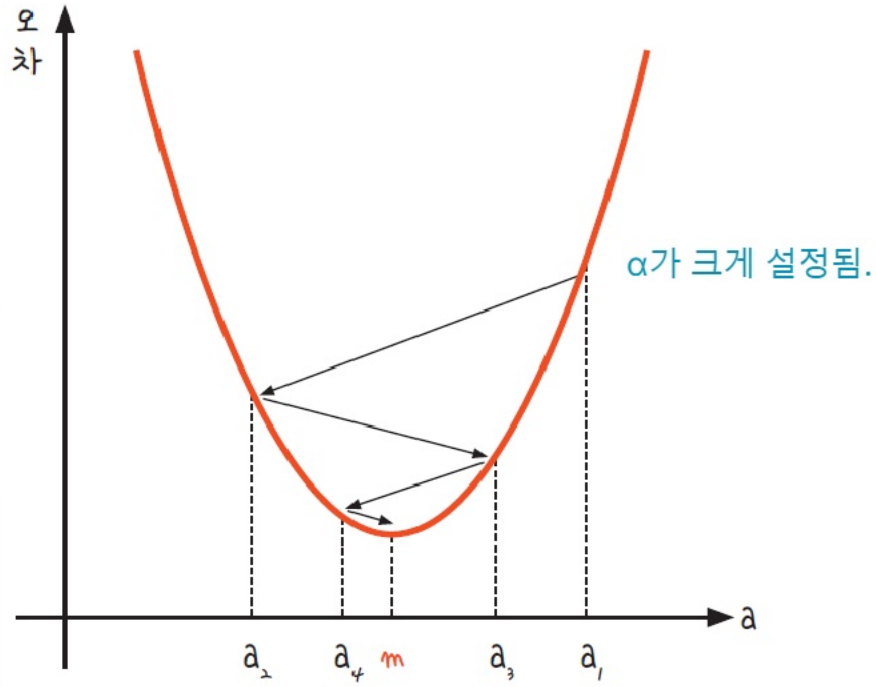

수렴

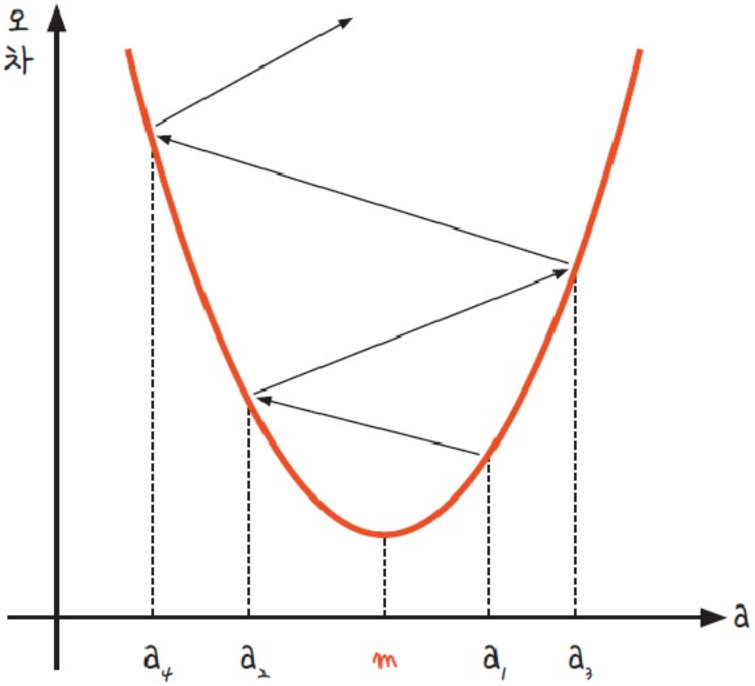

발산

학습률

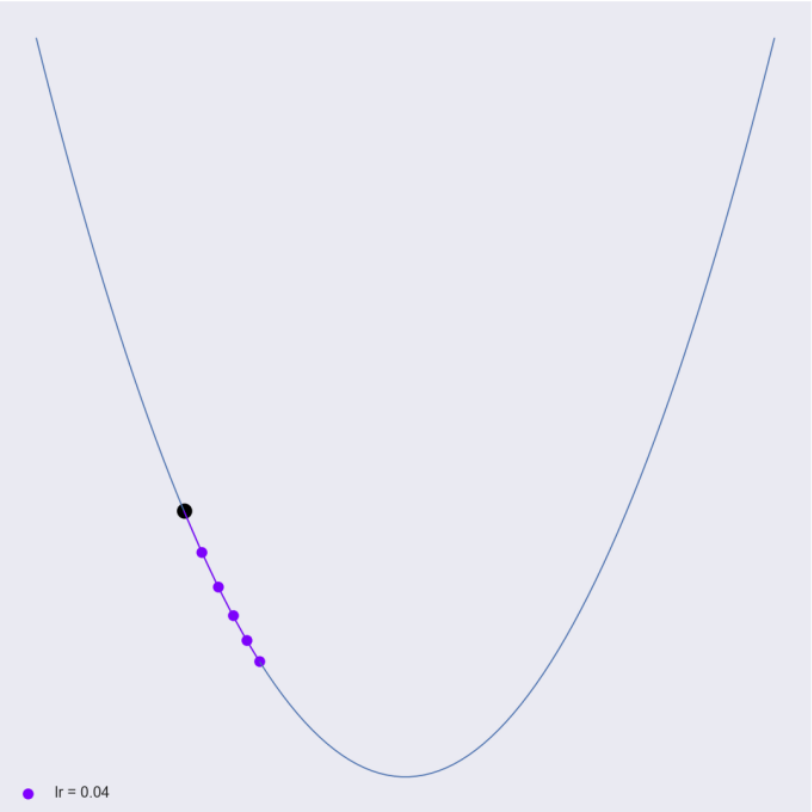

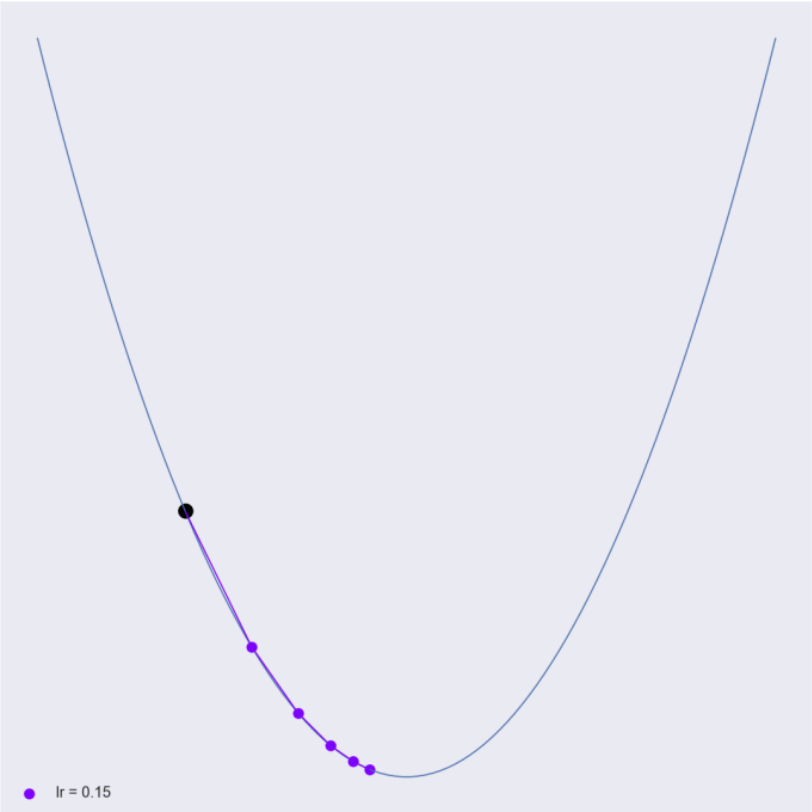

학습률

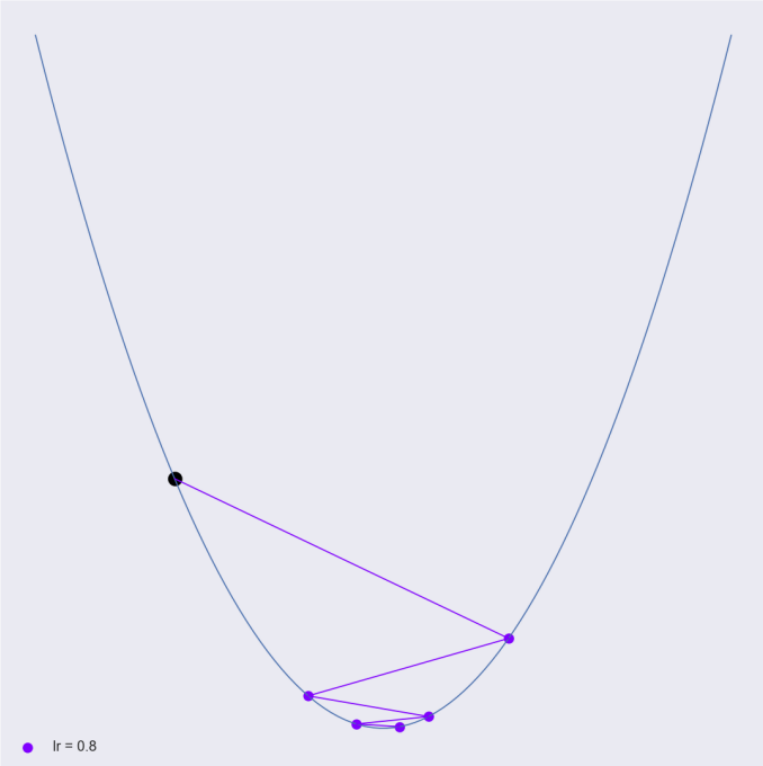

학습률

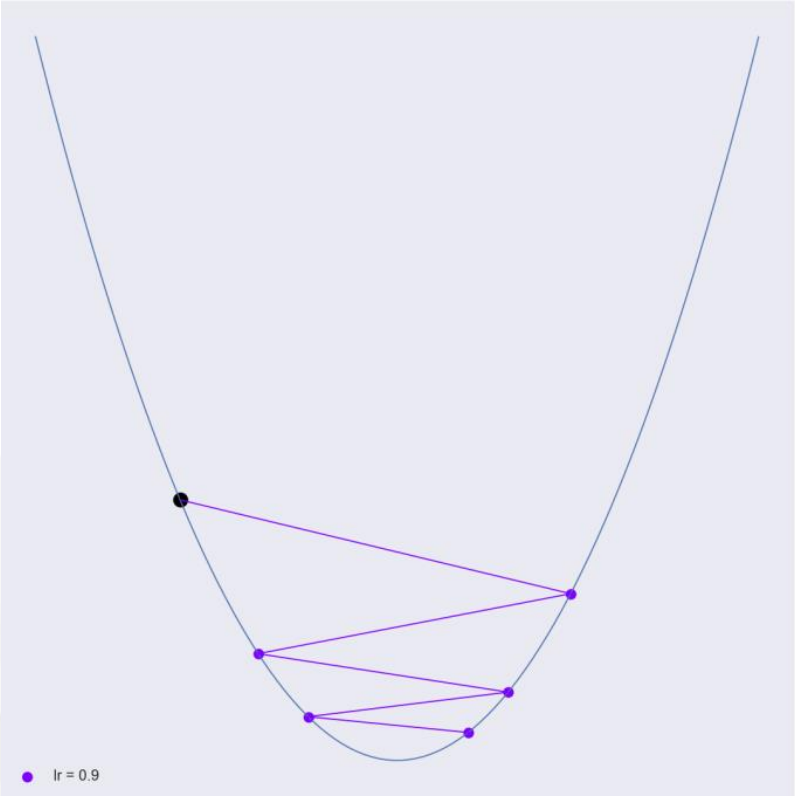

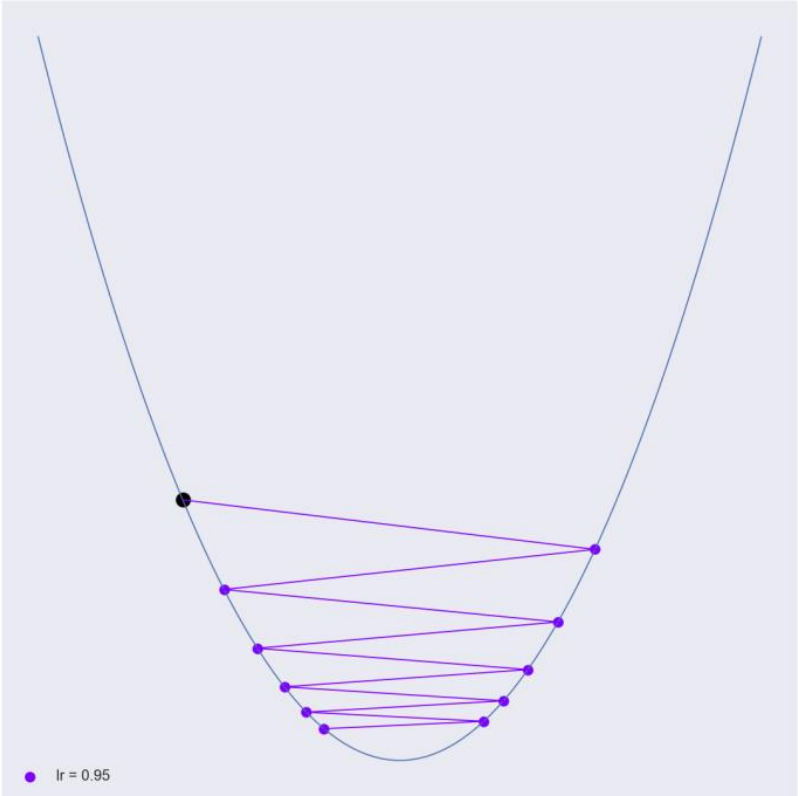

학습률

학습이 되고 있다고 볼 수 없음!

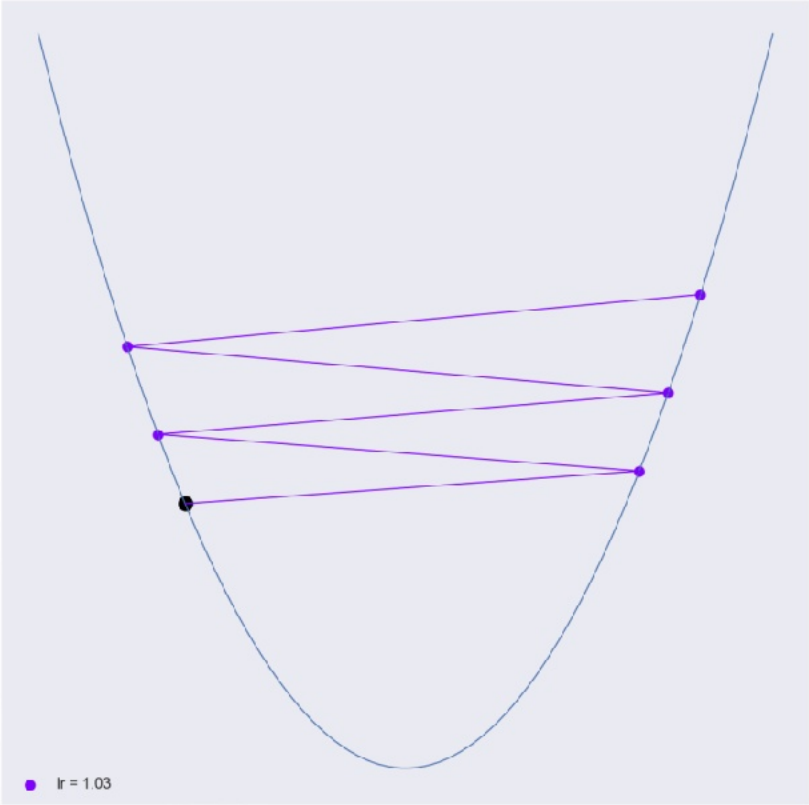

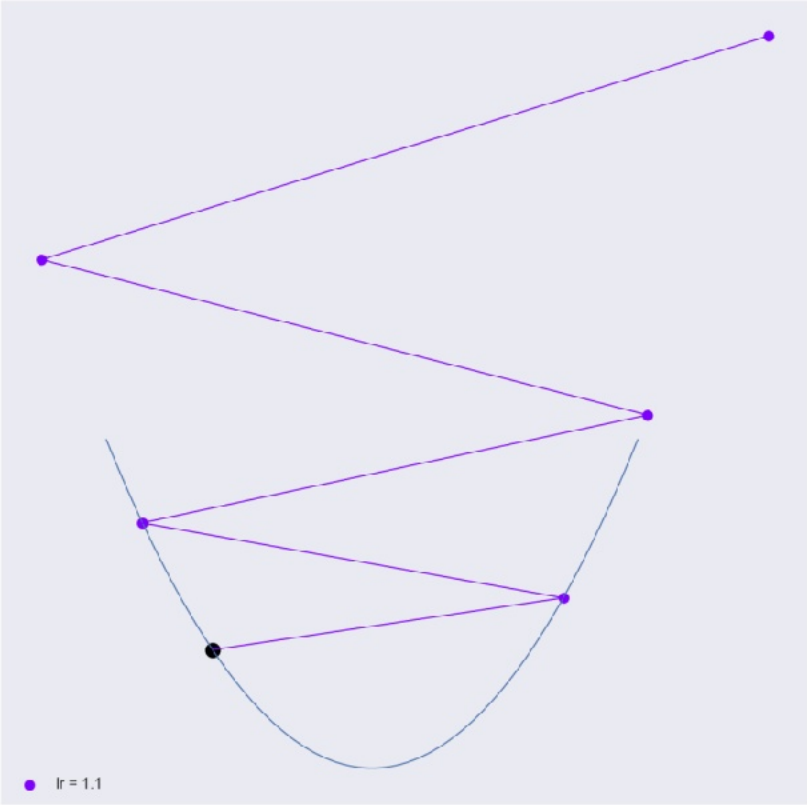

학습률

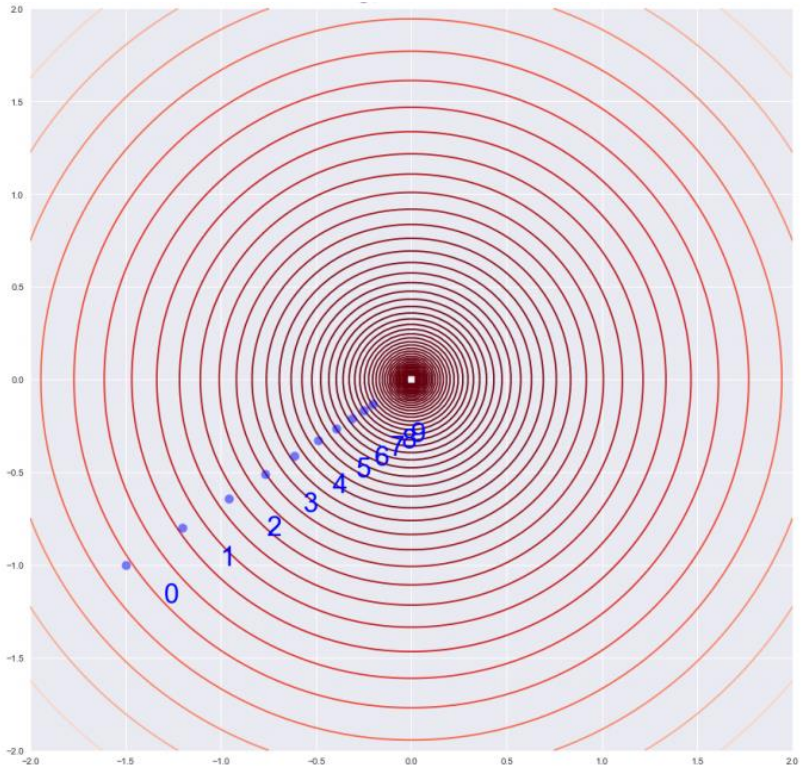

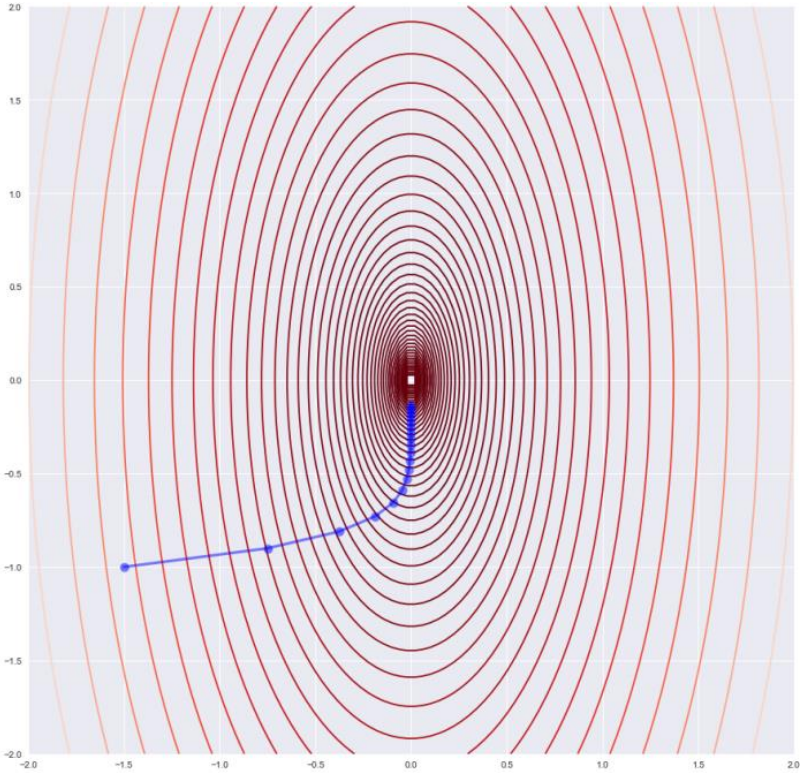

최적화 알고리즘 (Coming Soon..)

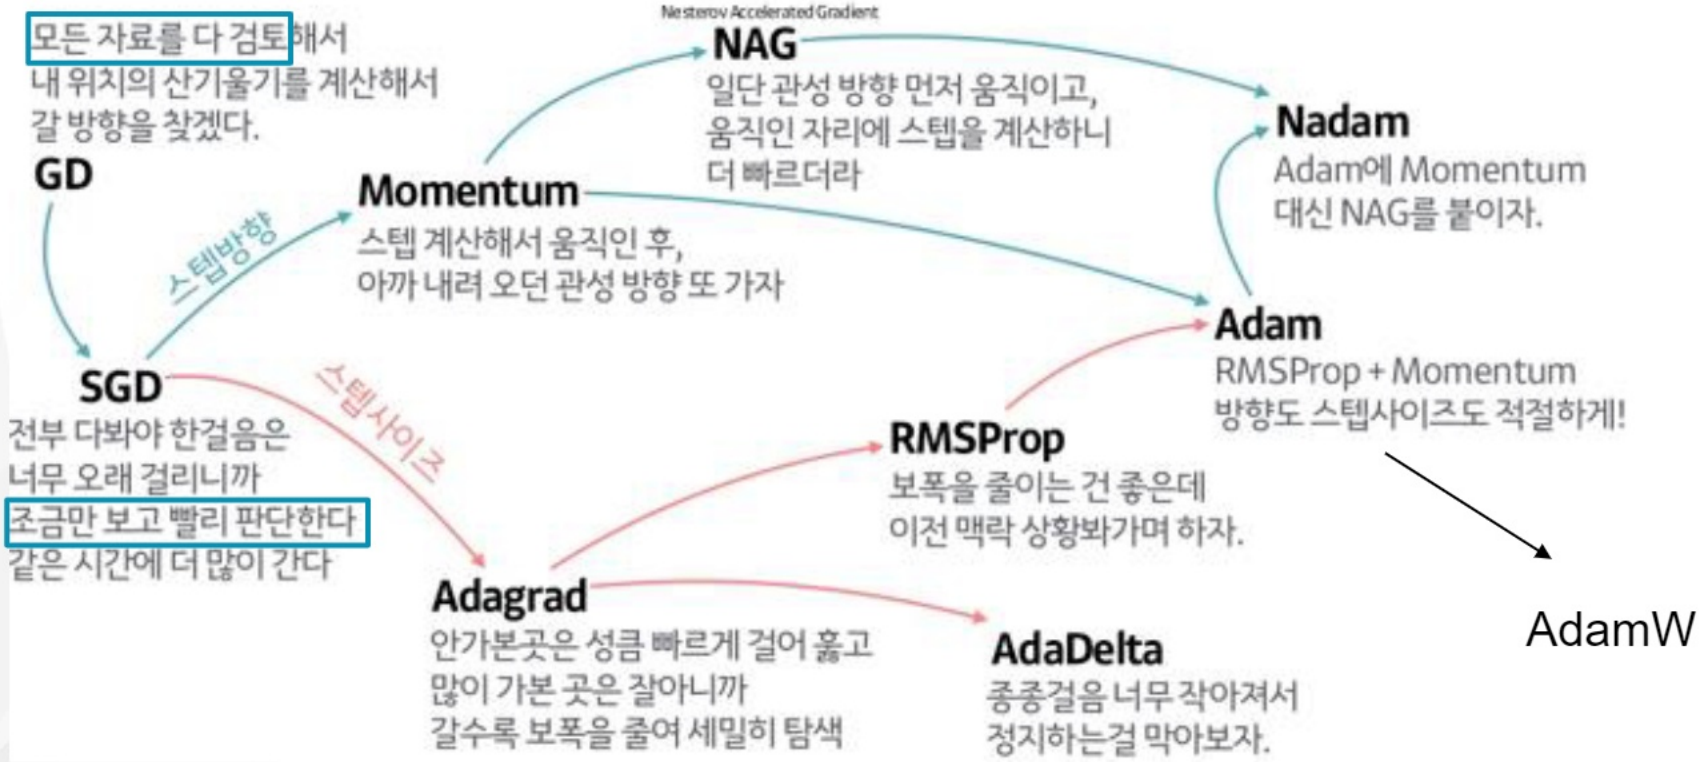

참고 문헌

- 모두의 딥러닝, 조태호 지음, 길벗
- 케라스 창시자에게 배우는 딥러닝, 프랑소와 숄레, 길벗
- 모두를 위한 머신러닝/딥러닝 (홍콩과기대 김성훈교수)
  http://hunkim.github.io/ml/
- Stanford Machine Learning http://www.holehouse.org/mlclass/
- Machine Learning (한성대 지준교수) http://jun.hansung.ac.kr/ml
- 수학적으로 접근하는 딥러닝 올인원 패키지, 신경식, 패스트 캠퍼스 신경식