소프트맥스 회귀

국립금오공과대학교
시종욱

목차

- 특징의 유형
- 소프트맥스 함수
- 원-핫 인코딩
- 크로스 앤트로피

특징의 유형

- 특징(Feature)
  - 연속 수치형 ~ continuous numerical type
    - ✓ 꽃잎 길이(petal length), 몸무게(length of body) 등
  - 순서 있는 범주형 ~ ordinal (discrete/ranked) type
    - ✓ 학년: 초등1~6/중등1~3/고등1~3
    - ✓ 서비스 만족도: Good, Neutral, Bad
  - 순서 없는 범주형 ~ nominal (categorical) type (순서 무)
    - ✓ 정상/불량 (카드 사용)
    - ✓ virginica/setosa/versicolor (붓꽃 품종)
    - ✓ Korea/US/France/… (국가)
    - ✓ Black/Brown/Silver (머리카락 색상)

로지스틱 회귀

- 로지스틱 회귀(Logistic regression)
  - ➢ 일상 속 풀고자하는 많은 문제 중에서는 두 개의 선택지 중에서 정답을 고르는 문제가 많음
    - ✓ 시험을 봤는데 이 시험 점수가 합격인지 불합격인지가 궁금할 수도 있음
    - ✓ 어떤 메일을 받았을 때 이게 정상 메일인지 스팸 메일인지를 분류하는 문제
    - ✓ 이렇게 둘 중 하나를 결정하는 문제를 이진 분류(Binary Classification)라고 함
    - ✓ 그리고 이런 문제를 풀기 위한 대표적인 알고리즘으로 로지스틱 회귀(Logistic Regression)가 있음

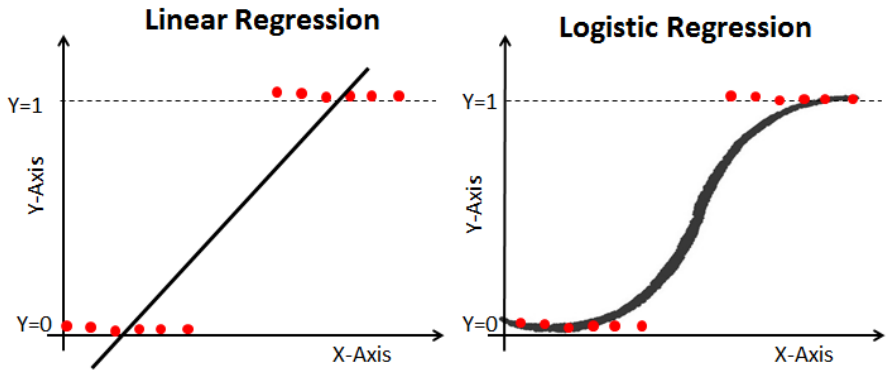

특징의 유형

- 로지스틱 회귀

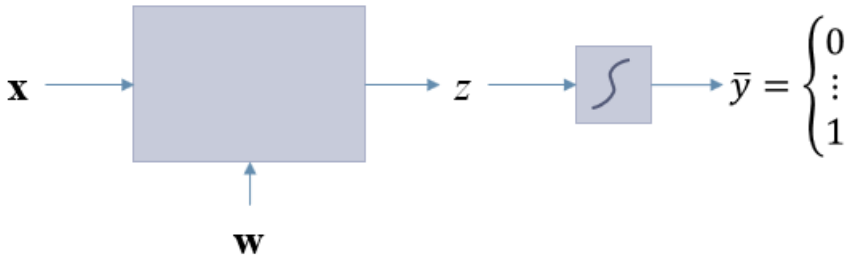

$$z = \mathbf{w}^T\mathbf{x}$$

$$H(\mathbf{x}) = \frac{1}{1+e^{-z}} = \frac{1}{1+e^{-\mathbf{w}^T\mathbf{x}}}$$

$$J(\mathbf{w}) = \frac{1}{n}\sum_{k=1}^{n} -y^{(k)} \cdot \log\left(H\left(x^{(k)}\right)\right) - \left(1-y^{(k)}\right)\log\left(1-H\left(x^{(k)}\right)\right)$$

특징의 유형

- 로지스틱 회귀

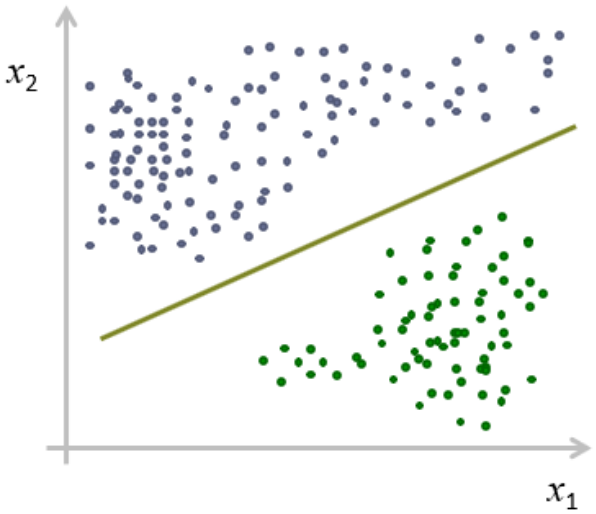

이진 분류(Binary Classification)

score(x)	result(y)
45	불합격
50	불합격
55	불합격
60	합격
65	합격
70	합격

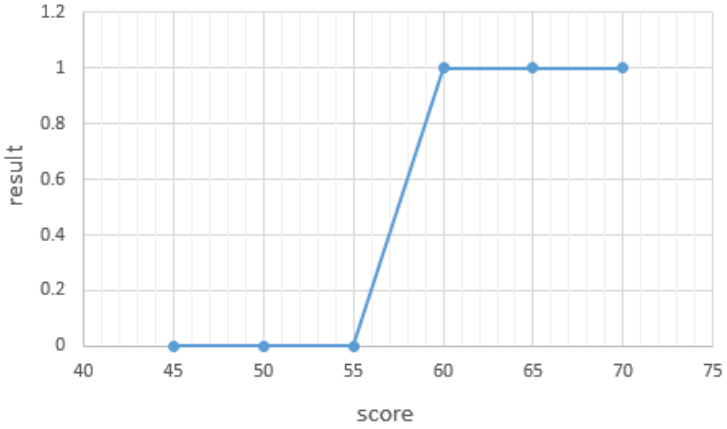

다항 로지스틱 회귀

- 다항 로지스틱 회귀(Multinomial Logistic regression)
  - 종속변수 Y가 3개 이상의 범주를 가질 때, 적용할 수 있는 로지스틱 회귀모델
  - Linear Regression에서 2개의 범주를 분류하는 함수로 Sigmoid를 사용했다면, 3개 이상의 여러 범주를 분류할때 사용하는 함수가 바로 Softmax함수

다항 로지스틱 회귀

- 다항 로지스틱 회귀(Multinomial Logistic regression)

공부 시간(x_1)	결석일(x_2)	과목 등급(y)
9	5	**C**
30	2	**A**
17	6	**B**
2	1	**C**
40	0	**A**
35	10	**B**

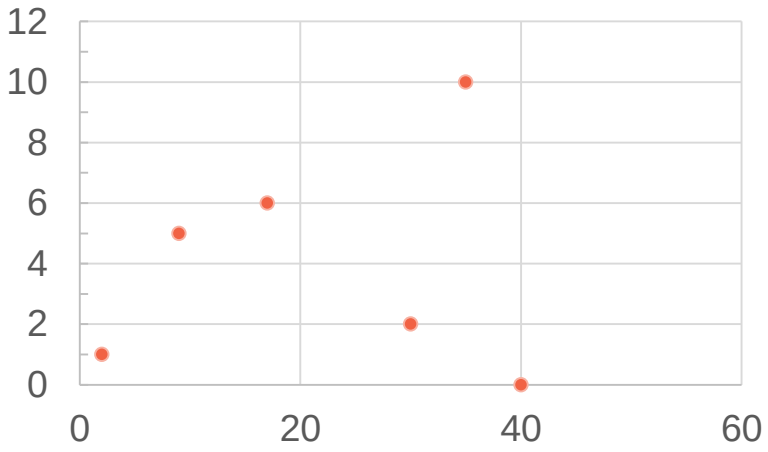

다항 로지스틱 회귀

- 다항 로지스틱 회귀(Multinomial Logistic regression)

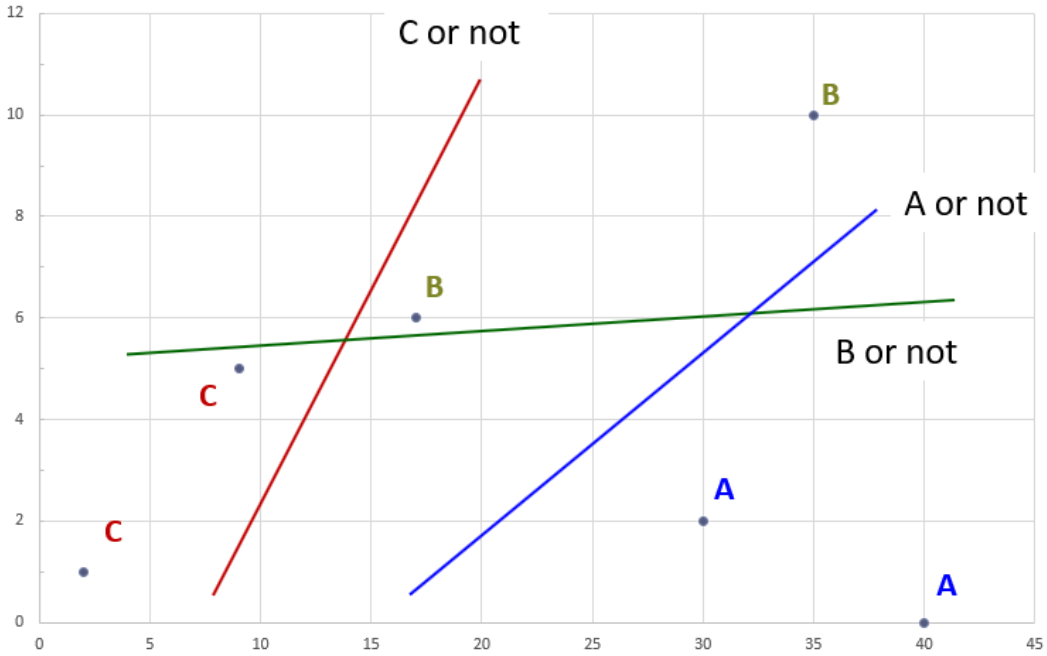

다항 로지스틱 회귀

- 다항 로지스틱 회귀(Multinomial Logistic regression)

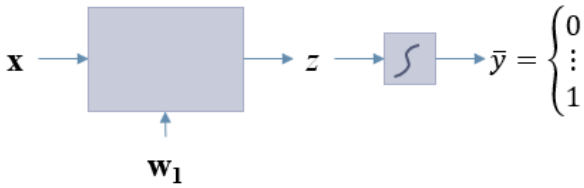

A $\quad [w_{11} \quad w_{12}] \cdot \begin{bmatrix} x_1 \\ x_2 \end{bmatrix} = w_{11}x_1 + w_{12}x_2$

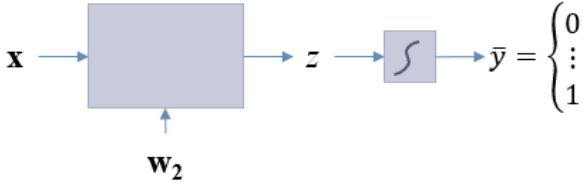

B $\quad [w_{21} \quad w_{22}] \cdot \begin{bmatrix} x_1 \\ x_2 \end{bmatrix} = w_{21}x_1 + w_{22}x_2$

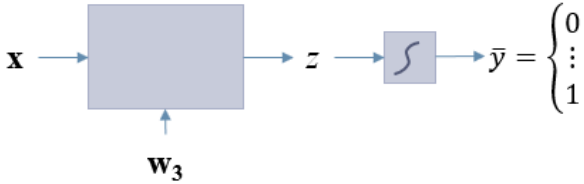

C $\quad [w_{31} \quad w_{32}] \cdot \begin{bmatrix} x_1 \\ x_2 \end{bmatrix} = w_{31}x_1 + w_{32}x_2$

다항 로지스틱 회귀

- 다항 로지스틱 회귀(Multinomial Logistic regression)

$$[w_{A1} \quad w_{A2}] \cdot \begin{bmatrix} x_1 \\ x_2 \end{bmatrix} = w_{A1}x_1 + w_{A2}x_2$$

$$[w_{B1} \quad w_{B2}] \cdot \begin{bmatrix} x_1 \\ x_2 \end{bmatrix} = w_{B1}x_1 + w_{B2}x_2$$

$$[w_{C1} \quad w_{C2}] \cdot \begin{bmatrix} x_1 \\ x_2 \end{bmatrix} = w_{C1}x_1 + w_{C2}x_2$$

$$\begin{bmatrix} w_{A1} & w_{A2} \\ w_{B1} & w_{B1} \\ w_{C1} & w_{C1} \end{bmatrix} \cdot \begin{bmatrix} x_1 \\ x_2 \end{bmatrix} = \begin{bmatrix} w_{A1}x_1 + w_{A2}x_2 \\ w_{B1}x_1 + w_{B2}x_2 \\ w_{C1}x_1 + w_{C2}x_2 \end{bmatrix} = \begin{bmatrix} \overline{y_{\mathrm{A}}} \\ \overline{y_{\mathrm{B}}} \\ \overline{y_{\mathrm{C}}} \end{bmatrix}$$

Sigmoid 함수는?

다항 로지스틱 회귀

- 다항 로지스틱 회귀(Multinomial Logistic regression)

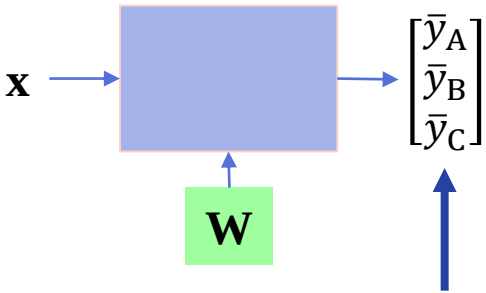

각 출력이 0~1이고
모두 합쳐서 1이 되도록!

소프트맥스

- 소프트맥스(Softmax)
  - k차원 벡터에서 i번째 원소를 z_i, i번째 클래스가 정답일 확률을 p_i라고 했을 때 소프트맥스 함수는 아래와 같이 정의

$$p_i = \frac{e^{z_i}}{\sum_{j=1}^{k} e^{z_j}} \quad for\ i = 1, 2, \ldots k$$

$$softmax(z) = [\frac{e^{z_1}}{\sum_{j=1}^{3} e^{z_j}} \ \frac{e^{z_2}}{\sum_{j=1}^{3} e^{z_j}} \ \frac{e^{z_3}}{\sum_{j=1}^{3} e^{z_j}}] = [p_1, p_2, p_3] = \hat{y} = \text{예측값}$$

$$softmax(z) = [\frac{e^{z_1}}{\sum_{j=1}^{3} e^{z_j}} \ \frac{e^{z_2}}{\sum_{j=1}^{3} e^{z_j}} \ \frac{e^{z_3}}{\sum_{j=1}^{3} e^{z_j}}] = [p_1, p_2, p_3] = [p_{virginica}, p_{setosa}, p_{versicolor}]$$

소프트맥스

- 소프트맥스(Softmax)

$$\begin{bmatrix} w_{A1} & w_{A2} \\ w_{B1} & w_{B1} \\ w_{C1} & w_{C1} \end{bmatrix} \cdot \begin{bmatrix} x_1 \\ x_2 \end{bmatrix} = \begin{bmatrix} w_{A1}x_1 + w_{A2}x_2 \\ w_{B1}x_1 + w_{B2}x_2 \\ w_{C1}x_1 + w_{C2}x_2 \end{bmatrix} = \begin{bmatrix} \overline{y_{\mathrm{A}}} \\ \overline{y_{\mathrm{B}}} \\ \overline{y_{\mathrm{C}}} \end{bmatrix}$$

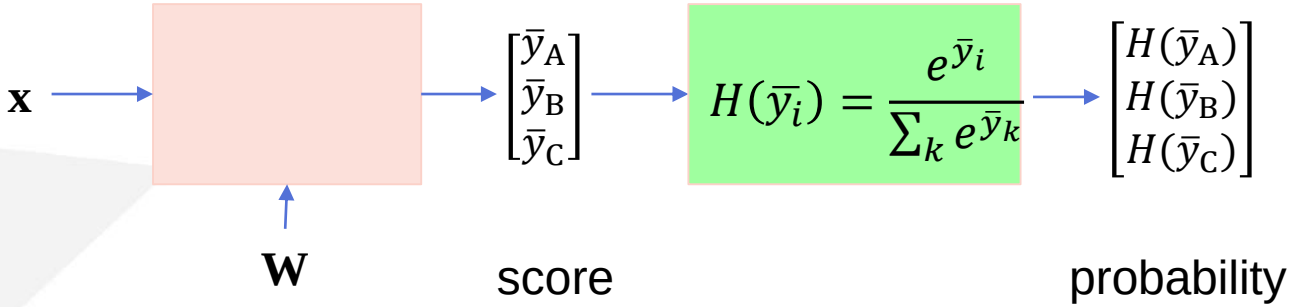

원-핫 인코딩

- 원-핫 인코딩(One-hot Encoding)

$$\bar{\mathbf{y}} = \begin{bmatrix} 7.0 \\ 2.0 \\ 0.5 \end{bmatrix} \rightarrow H(\bar{\mathbf{y}}) = \begin{bmatrix} 0.74 \\ 0.21 \\ 0.05 \end{bmatrix} \rightarrow R(\bar{\mathbf{y}}) = \begin{bmatrix} 1.0 \\ 0.0 \\ 0.0 \end{bmatrix}$$

속성 클래스

샘플

	정보 1	정보 2	정보 3	정보 4	품종		
1번째 아이리스	5.1	3.5	4.0	0.2	Iris-setosa	1	[0., 1., 0.]
2번째 아이리스	4.9	3.0	1.4	0.2	Iris-setosa	1	[0., 1., 0.]
3번째 아이리스	4.7	3.2	1.3	0.3	Iris-setosa	1	[0., 1., 0.]
...	...	...	...	...	...		
150번째 아이리스	5.9	3.0	5.1	1.8	Iris-virginica	0	[1., 0., 0.]

크로스 앤트로피

- 크로스 앤트로피(Cross Entropy)
  - 엔트로피와 상당히 유사한 개념이다. 엔트로피가 정답이 나올 확률만을 대상으로 측정한 값이었다면 크로스 엔트로피는 모델에서 예측한 확률과 정답확률을 모두 사용해 측정한 값이다.
  - 크로스 엔트로피는, 모델에서 예측한 확률값이 실제값과 비교했을 때 틀릴 수 있는 정보량을 의미한다. 엔트로피와 마찬가지로 그 값이 적을 수록 모델이 데이터를 더 잘 예측하는 모델임을 의미한다.
  - 딥러닝의 손실함수로 많이 사용되는 개념으로 딥러닝 모델에선 예측값과 정답값의 크로스 엔트로피 값을 줄이기 위해 가중치와 편향을 업데이트하며 학습을 수행한다.

$$loss(\bar{\mathbf{y}}) = -\sum_{i} y_i \cdot \log(\bar{y}_i)$$

크로스 앤트로피

- 크로스 앤트로피(Cross Entropy)
  - 앤트로피 vs 크로스 앤트로피
  - 앤트로피에서 어떤 특정 현상이 발생할 확률 : p
  - 크로스 앤트로피에서 각 클래스에 대해 예측한 확률값을 q, 실제 값의 확률을 p

$$h(x) = -\sum_{i=1}^{n} (pi \log_2(pi))$$

$$h(p, q) = -\sum_{i=1}^{n} (\log_2(qi)pi)$$

크로스 앤트로피

- 크로스 앤트로피(Cross Entropy)

$$loss(\bar{\mathbf{y}}) = -\sum_i y_i \cdot \log(\bar{y}_i)$$

$$= \sum_i y_i \cdot (-\log(\bar{y}_i))$$

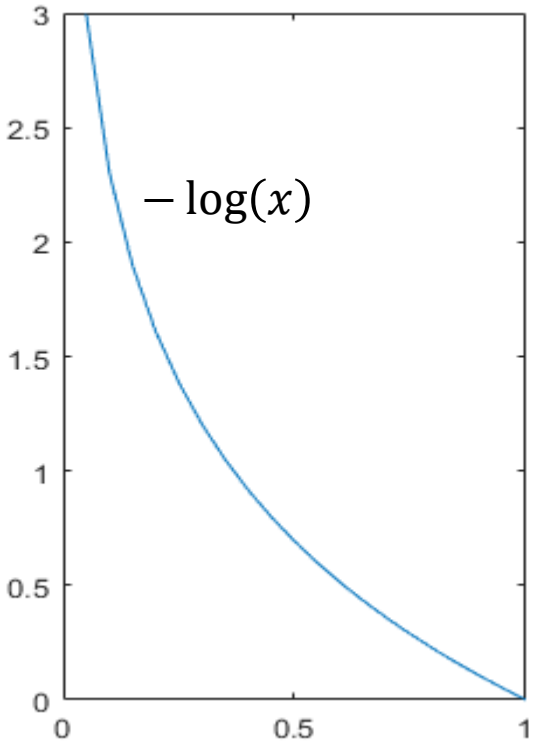

크로스 앤트로피

- 크로스 앤트로피(Cross Entropy)

[정답]

$$\mathbf{y} = \begin{bmatrix} 1.0 \\ 0.0 \\ 0.0 \end{bmatrix}$$

[예측 경우1]

$$\bar{\mathbf{y}} = \begin{bmatrix} 0.9 \\ 0.0 \\ 0.1 \end{bmatrix}$$

cost는 0 부근이 됨

[예측 경우2]

$$\bar{\mathbf{y}} = \begin{bmatrix} 0.0 \\ 0.9 \\ 0.1 \end{bmatrix}$$

cost는 ∞가 됨

크로스 앤트로피

- 크로스 앤트로피(Cross Entropy)
  - 1) Q값: 0.0, 1.0, 1.0
    - ✓ 크로스 엔트로피: -(log 0 * 1 + log1 *0 + log1* 0)= Infinity
  - 2) Q값: 0.8, 0.1, 0.1
    - ✓ 크로스 엔트로피: -(log 0.8 * 1 + log 0.1 * 0 + log 0.1 * 0) = 0.32
  - 3) Q값: 1, 0, 0
    - ✓ 크로스 엔트로피: -(log 1 * 1 + log 0 * 0 + log 0* 0) = 0

크로스 앤트로피

- 로지스틱 vs. 크로스 앤트로피(Cross Entropy)
  - 형태는 다르지만 의미는 동일

$$loss(\bar{\mathrm{y}}) = -y \cdot \log(\bar{\mathrm{y}}) - (1-y)\log(1-H(\bar{\mathrm{y}}))$$

$$loss(\bar{\mathbf{y}}) = -\sum_i y_i \cdot \log(\bar{y}_i)$$

비용 함수

- 비용 함수(Cost Function)

$$loss(\bar{\mathbf{y}}) = -\sum_{i} y_i \cdot \log(\bar{y}_i)$$

$$J(\mathbf{w}) = \frac{1}{n}\sum_{k=1}^{n} loss(\bar{\mathbf{y}}) = \frac{1}{n}\sum_{k=1}^{n}\left(-\sum_{i} y_i^{(k)} \cdot \log\left(\bar{y}_i^{(k)}\right)\right)$$

비용 함수

- 비용 함수(Cost Function) 최소화

$$J(\mathbf{w}) = \frac{1}{n}\sum_{k=1}^{n} loss(\bar{\mathbf{y}}) = \frac{1}{n}\sum_{k=1}^{n}\left(-\sum_{i} y_i^{(k)} \cdot \log\left(\bar{y}_i^{(k)}\right)\right)$$

Gradient descent:

$$\mathbf{w}^{(t+1)} := \mathbf{w}^{(t)} - \alpha \frac{\partial}{\partial w_{ki}} J(\mathbf{w})$$

for $k = 0, 1, 2, \cdots, n$

for $i = 0, 1, 2, \cdots, m$

관련 Loss

- Categorical Cross-Entropy Loss
  - Softmax activation 뒤에 Cross-Entropy loss를 붙인 형태로 주로 사용: Softmax loss 라고도 함
  - Multi-class classification에 사용

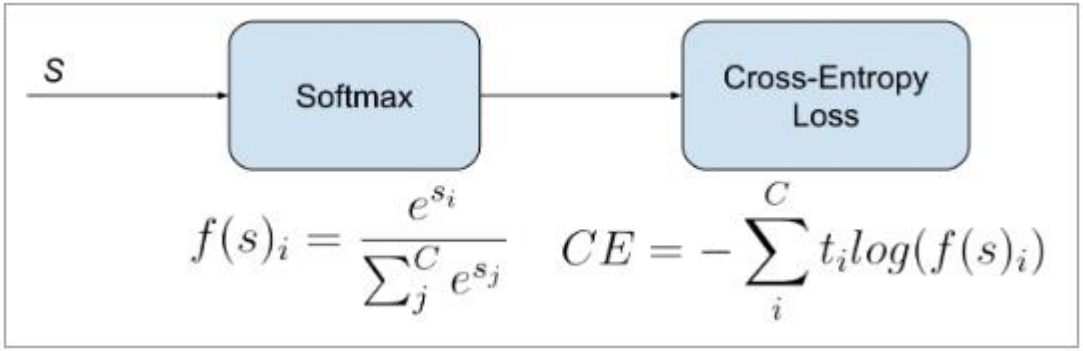

관련 Loss

- Binary Cross Entropy Loss
  - Sigmoid activation 뒤에 Cross-Entropy loss를 붙인 형태로 주로 사용: Sigmoid CE loss라고도 함
  - Multi-label classification에 사용

$$CE = -\sum_{i=1}^{C'=2} t_i log(f(s_i)) = -t_1 log(f(s_1)) - (1-t_1) log(1-f(s_1))$$

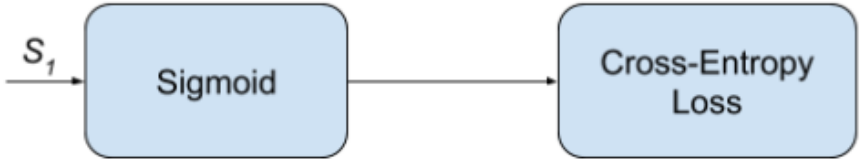

$$CE = -t_1 log(f(s_1)) - (1-t_1) log(1-f(s_1))$$

$$f(s_i) = \frac{1}{1+e^{-s_i}}$$

관련 Loss

$$FL = \begin{cases} -(1-s_1)^{\gamma} log(s_1) & if \quad t_1 = 1 \\ -(1-(1-s_1))^{\gamma} log(1-s_1) & if \quad t_1 = 0 \end{cases}$$

- Focal Loss

$$FL = -\sum_{i=1}^{C=2} (1-s_i)^{\gamma} t_i log(s_i)$$

  - https://arxiv.org/abs/1708.02002
  - Focal loss는 분류 에러에 근거한 loss에 가중치를 부여하는데, 샘플이 CNN에 의해 이미 올바르게 분류되었다면 그것에 대한 가중치는 감소
  - 즉, 좀 더 문제가 있는 loss에 더 집중하는 방식으로 불균형한 클래스 문제를 해결
  - Focal loss는 Sigmoid activation을 사용하기 때문에, Binary Cross-Entropy loss라고도 할 수 있음
  - γ = 0 일때 Focal loss는 Binary Cross Entropy Loss와 동일

관련 Loss

- Focal Loss

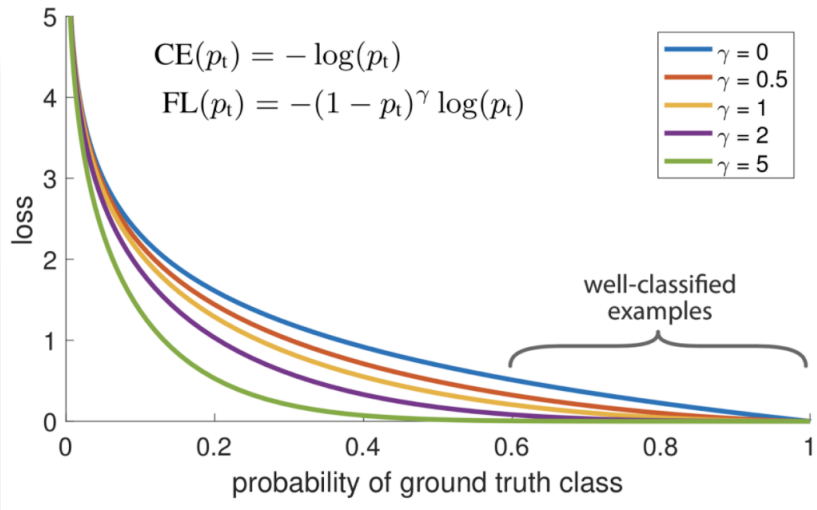

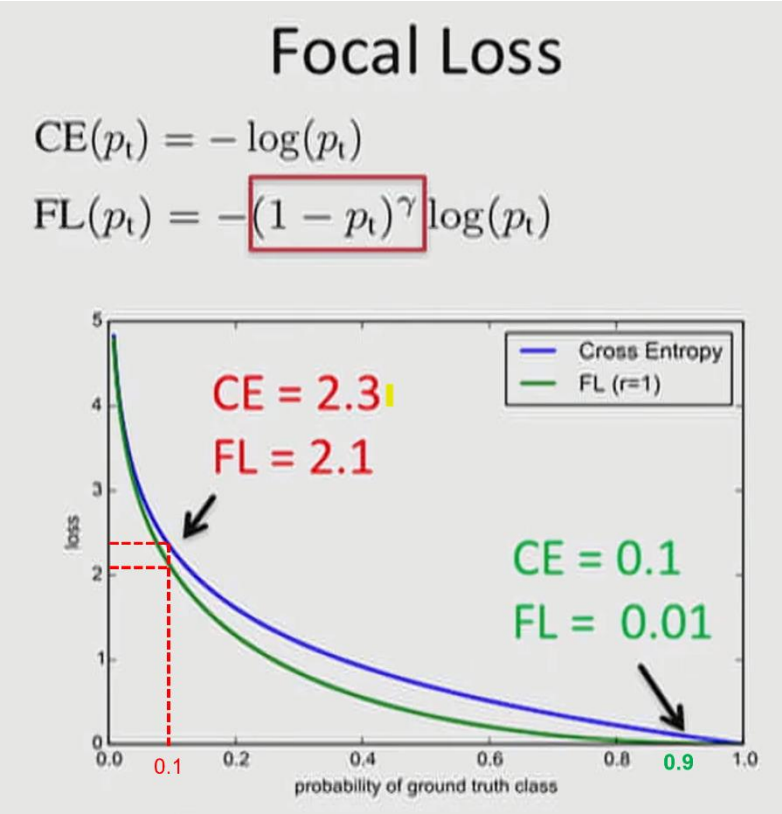

참고 문헌

- https://wikidocs.net/302606
- https://wikidocs.net/22881
- Stanford Machine Learning http://www.holehouse.org/mlclass/
- Deep Learning by Google https://www.udacity.com/course/deep-learning--ud730
- Machine Learning (한성대 지준교수) http://jun.hansung.ac.kr/ml
- 모두를 위한 머신러닝/딥러닝 (홍콩과기대 김성훈교수)

  http://hunkim.github.io/ml/
- https://gaussian37.github.io/dl-concept-focal_loss/