다중 분류 문제 해결하기

국립금오공과대학교
시종욱

목차

- 다중 분류 문제(붓꽃 품종) 해결

문제 정의

- 붓꽃(iris) 품종 예측: 꽃잎 모양과 길이를 기준으로 품종 구분

Iris–virginica

Iris–setosa

Iris–versicolor

데이터셋 확인

속성 클래스

샘플

	정보 1	정보 2	정보 3	정보 4	품종
1번째 아이리스	5.1	3.5	4.0	0.2	Iris-setosa
2번째 아이리스	4.9	3.0	1.4	0.2	Iris-setosa
3번째 아이리스	4.7	3.2	1.3	0.3	Iris-setosa
...	...	...	...	...	...
150번째 아이리스	5.9	3.0	5.1	1.8	Iris-virginica

샘플 수: 150개

속성 수: 4개
- 꽃받침 길이 (sepal length, cm)
- 꽃받침 너비 (sepal width, cm)
- 꽃잎 길이 (petal length, cm)
- 꽃잎 너비 (petal width, cm)

클래스: 3개
- Iris-setosa
- Iris-versicolor
- Iris-virginica

상관도 그래프

```
import pandas as pd
import seaborn as sns
import matplotlib.pyplot as plt

df = pd.read_csv(my_data, names = ["sepal_length", "sepal_width",
"petal_length", "petal_width", "species"])

sns.pairplot(df, hue='species');
plt.show()
```

상관도 그래프

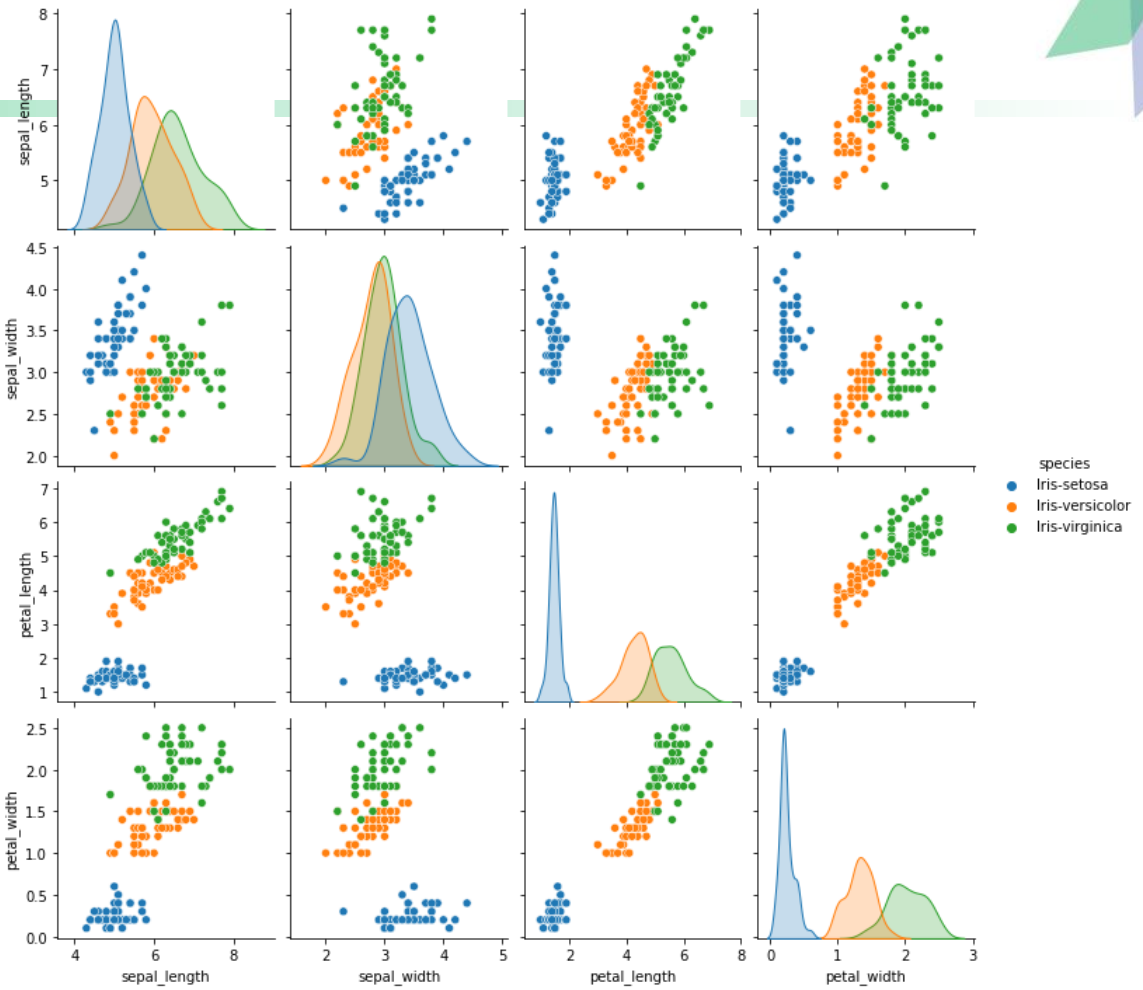
sepal_length
sepal_width
petal_length
petal_width
species
Iris-setosa
Iris-versicolor
Iris-virginica

원-핫 인코딩

```
from sklearn.preprocessing import LabelEncoder

e = LabelEncoder()
e.fit(Y_obj)
Y = e.transform(Y_obj)

Y_encoded = tf.keras.utils.to_categorical(Y)
```

[setosa setosa setosa . . .
Virginica virginica virginica]

```
[0 0 0 . . . 2 2 2]
```

```
[[1. 0. 0.]
 [1. 0. 0.]
 [1. 0. 0.]
    . . .
 [0. 0. 1.]
 [0. 0. 1.]
 [0. 0. 1.]]
```

모델 정의 및 컴파일

```
model = Sequential()
model.add(Dense(16,  input_dim=4, activation='relu'))
model.add(Dense(3, activation='softmax’))

model.compile(loss='categorical_crossentropy',
            optimizer='adam',
            metrics=['accuracy’])

model.fit(X, Y_encoded, epochs=50, batch_size=1)
```

연습(실습)

- 내용
  - 082_01_MC_Iris.ipynb
  - 082_02_MC_MNIST.ipynb
  - Tensorflow.org: 의류 영상 (fashion MNIST) 분류
  - https://www.tensorflow.org/tutorials/keras/classification?hl=ko
  - Tensorflow.org: 영화 리뷰 (IMDB) 분류
  - https://www.tensorflow.org/tutorials/keras/text_classification?hl=ko

MNIST

- MNIST Dataset

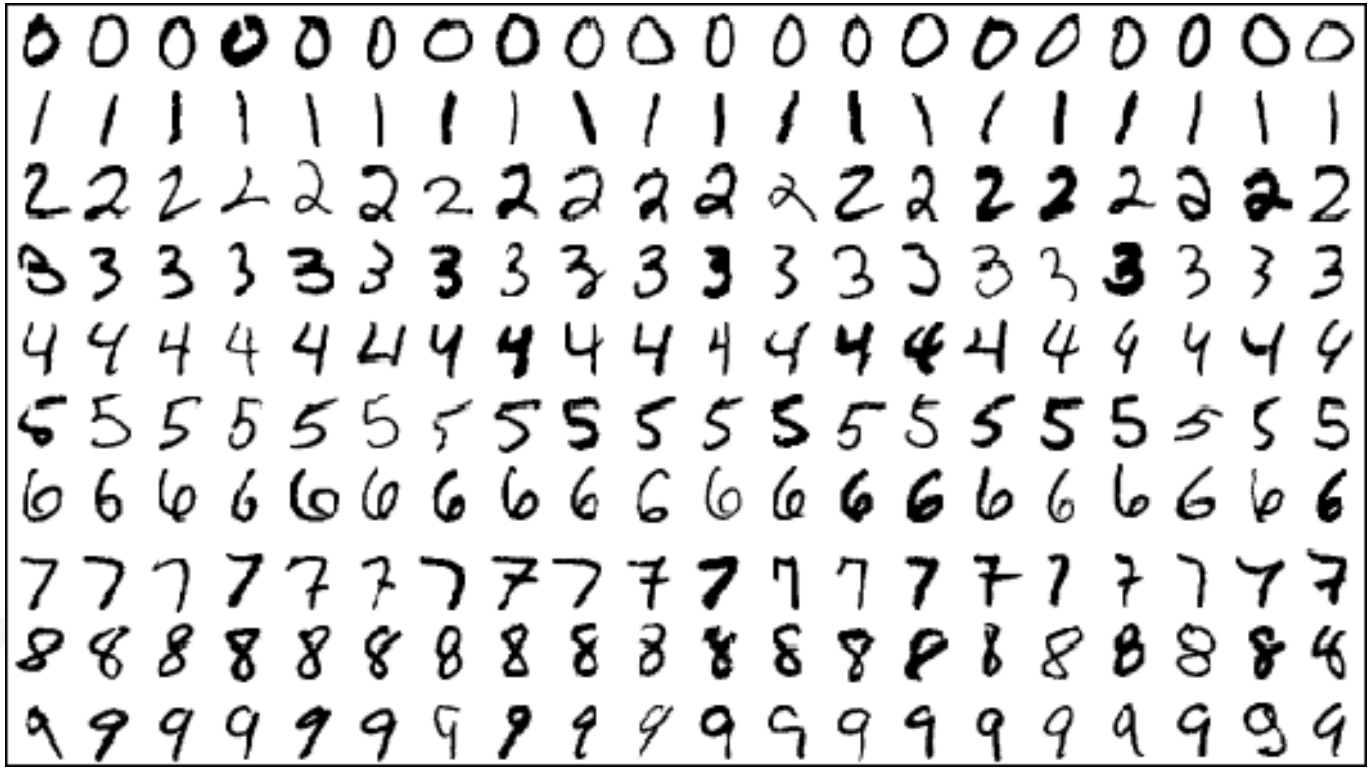

머신러닝의 Hello World 가
아이리스 데이터셋이라면
딥러닝에서는 MNIST 입니다.

Modified
National
Institute of
Standards and
Technology Database

MNIST는 손으로 쓴 숫자로 이루어진
대형 데이터베이스입니다.

1989 년 얀 레쿤 CNN 논문발표
1995 년 NIST 데이터셋 1st Ed. 발표
1998 년 MNIST 데이터셋 발표
2016 년 NIST 데이터셋 2nd Ed. 발표
2017 년 EMNIST 발표

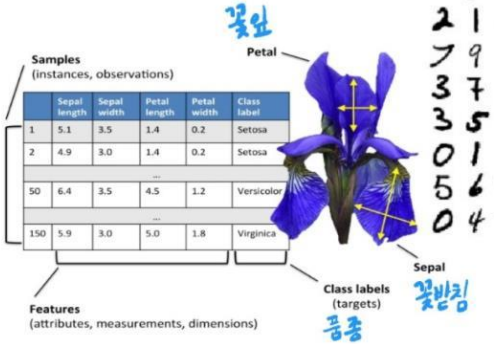

	Sepal length	Sepal width	Petal length	Petal width	Class label
1	5.1	3.5	1.4	0.2	Setosa
2	4.9	3.0	1.4	0.2	Setosa
			...		
50	6.4	3.5	4.5	1.2	Versicolor
			...		
150	5.9	3.0	5.0	1.8	Virginica

iris

MNIST

< MNIST 를 만든 분들 >

1986 년 NIST 에서는
손글씨 우편번호를 읽어
빠르게 분류할 수 있는 방법을 고민합니다.

수많은 우편물을 분류하는데
실수도 많고 비용도 많이 들었기 때문입니다.

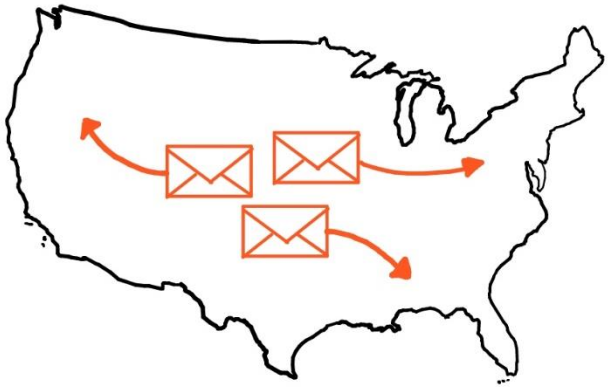

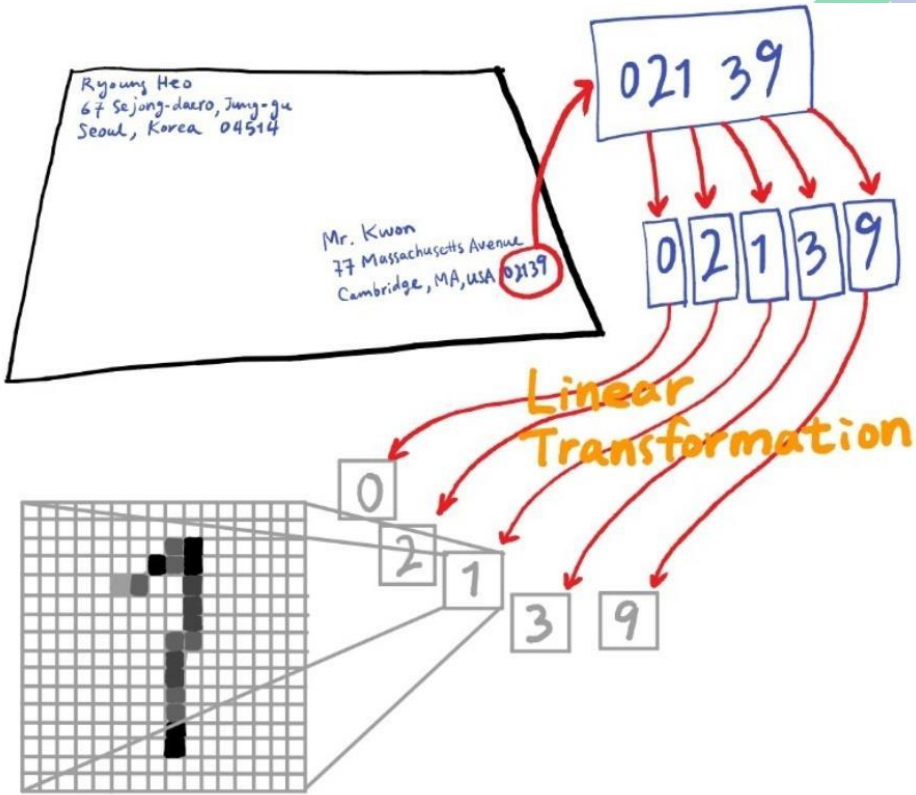

NIST는 이들을 비교·평가하기위해 정답이 필요했습니다.

이를 위해 아래 양식으로 글씨를 수집하여 데이터셋을 만듭니다.

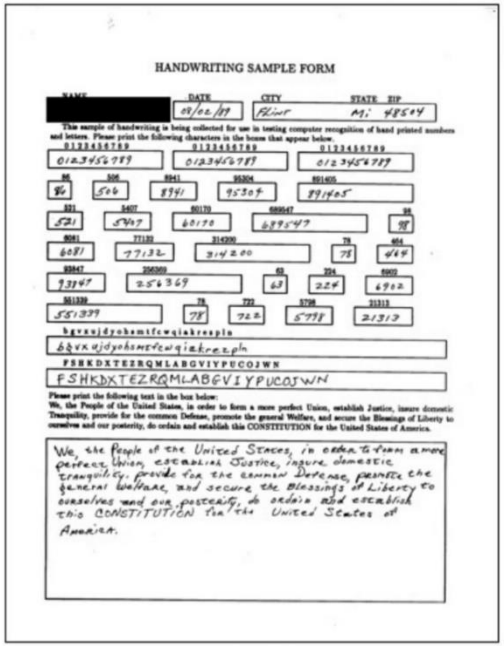
HANDWRITING SAMPLE FORM

NAME [redacted] DATE 08/02/89 CITY Flint STATE MI ZIP 48504

This sample of handwriting is being collected for use in testing computer recognition of hand printed numbers and letters. Please print the following characters in the boxes that appear below.

0123456789 0123456789 0123456789

0123456789 0123456789 0123456789

86 506 8941 95304 891405

521 5407 60170 689547 98

6081 77132 314200 78 464

93847 256369 63 224 6902

351339 78 722 5798 21313

bgvxujdyohsmtfcwqiakrezph

bgvxujdyohsmtfcwqiakrezph

FSHKDXTEZRQMLABGVIYPUCOJWN

FSHKDXTEZRQMLABGVIYPUCOJWN

Please print the following text in the box below:

We, the People of the United States, in order to form a more perfect Union, establish Justice, insure domestic Tranquility, provide for the common Defense, promote the General Welfare, and secure the Blessings of Liberty to ourselves and our posterity, do ordain and establish this CONSTITUTION for the United States of America.

We, the People of the United States, in order to form a more perfect Union, establish Justice, insure domestic tranquility, provide for the common Defense, promote the general Welfare, and secure the Blessings of Liberty to ourselves and our posterity, do ordain and establish this CONSTITUTION for the United States of America.

그렇게 NIST 데이터셋 기반으로 MNIST가 만들어 집니다.

MNIST는 고등학생들의 글씨인 NIST SD-1과 인구조사국 직원들의 글씨인 NIST SD-3로부터 데이터를 가져왔습니다.

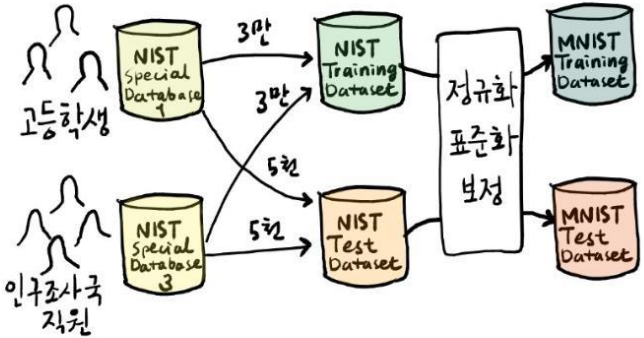

그 데이터로부터 일반화·표준화와 약간의 수정을 거쳐 생성한 것이 MNIST 데이터셋입니다.

연습가능한 데이터셋

- Scikit-Learn 제공 데이터세트
  - https://scikit-learn.org/stable/datasets.html

- 와인 데이터
  - https://scikit-learn.org/stable/modules/generated/sklearn.datasets.load_wine.html
- 숫자 데이터
  - https://scikit-learn.org/stable/modules/generated/sklearn.datasets.load_digits.html
- 유방암 데이터
  - https://scikit-learn.org/stable/modules/generated/sklearn.datasets.load_breast_cancer.html

참고 문헌

- Stanford Machine Learning http://www.holehouse.org/mlclass/
- Deep Learning by Google https://www.udacity.com/course/deep-learning--ud730
- Machine Learning (한성대 지준교수) http://jun.hansung.ac.kr/ml
- 모두를 위한 머신러닝/딥러닝 (홍콩과기대 김성훈교수)

  http://hunkim.github.io/ml/